

Оглавление

Аннотация.....	3
Введение	4
Основная часть	6
1. Обзор литературы	6
1.1. Современное состояние области исследования непараметрических методов	6
1.2. Текущие результаты из области оценивания регрессии.....	9
1.3. Перспективные походы оценивания регрессии	10
2. Постановка задачи, генерация и сбор данных	15
2.1. Формальная постановка задачи оценки одномерной регрессии	15
2.2. Общее описание датасетов	15
3. Обзор используемых методов.....	25
3.1. Ядерное сглаживание.....	25
3.2. Информационный подход	31
4. Практическая часть.....	40
4.1. Генерация датасетов	40
4.2. Оценка моделей на синтетических данных	51
4.3. Оценка моделей на реальных данных	74
Заключение.....	76
ПРИЛОЖЕНИЕ 2.....	78
ПРИЛОЖЕНИЕ 3.....	81

Аннотация

Работа посвящена оценке регрессионной зависимости в условиях малых выборок и нарушения предположений о распределении ошибок. Цель исследования – построение робастных оценок регрессии без априорных предположений о шуме на основе энтропийных принципов. Задачи: реализация модифицированного энтропийного метода, сравнение его с классической ядерной регрессией на синтетических и реальных данных, анализ устойчивости к шуму.

Экспериментально подтверждена эффективность метода «мягкой» энтропии. На синтетических данных с малыми выборками и сложным распределением ошибок предложенный метод показал статистически значимое превосходство над ядерными подходами по метрикам IMSE, IMAE и MaxErr. Подход продемонстрировал высокую робастность к выбросам, предотвращая переобучение за счёт склонности к выбору более простых моделей. На реальных данных большего объёма энтропийный метод сохранил конкурентоспособность, уступая ядерной регрессии незначительно (3–4%).

Рекомендовано применять разработанный энтропийный метод в задачах с ограниченным объёмом данных, наличием выбросов или нестандартным шумом. Для выборок большого размера со сложной непараметрической структурой предпочтительны классические методы ядерного сглаживания. Перспективным направлением развития считается создание гибридных моделей.

Введение

В современном анализе данных задача оценки регрессионной зависимости является одной из классических и часто встречающихся задач^{1 2 3}. Согласно статье⁴ Анатольева С. можно выделить два основных подхода к её решению – непараметрические⁵ и параметрические⁶ методы. Непараметрическая регрессия⁷ – это метод представления зависимости между переменными, который не предполагает явно заданной параметризации. Основное преимущество такого подхода заключается в возможности описания сложной зависимости без предположений о ее параметрической структуре. Метод позволяет анализировать данные со сложной структурой (нелинейность, выбросы, мультимодальность), которые трудно оценить параметрическими методами. Широкое применение данный метод находит в машинном обучении и прикладных областях: экономике⁸ и медицине⁹. Стандартным подходом непараметрического оценивания является метод ядерного сглаживания, при этом его эффективность существенно зависит как от размерности задачи, так и от размера выборки, поскольку отсутствие параметризации приводит к необходимости оценивать по сути бесконечное число неявно заданных параметров в задаче¹⁰. В условиях малых выборок оценка гиперпараметров сглаживания (например, методами кросс-валидации или бутстрапа) по этой причине становится нестабильной.

¹ Alberto Caron, Gianluca Baio, Ioanna Manolopoulou, Estimating Individual Treatment Effects using Non-Parametric Regression Models: a Review, Journal of the Royal Statistical Society Series A: Statistics in Society, Volume 185, Issue 3, July 2022, Pages 1115–1149, <https://doi.org/10.1111/rssa.12824>

² Mingming Zhang, Zikun Yang, Liyun Liu, Dequn Zhou, Impact of renewable energy investment on carbon emissions in China - An empirical study using a nonparametric additive regression model, Science of The Total Environment, Volume 785, 2021, 147109, ISSN 0048-9697, <https://doi.org/10.1016/j.scitotenv.2021.147109>.

³ Cheng, Tingting and Gao, Jiti and Linton, Oliver B. and Yan, Yayi, Nonparametric Predictive Regression for Stock Return Prediction 1 (February 05, 2025). Available at SSRN: <https://ssrn.com/abstract=5126279> or <http://dx.doi.org/10.2139/ssrn.5126279>

⁴ Anatolyev, Stanislav. (2009). Nonparametric regression (in Russian). Quantile. 37-52.

⁵ Там же.

⁶ Дрейпер Н., Смит Г. Прикладной регрессионный анализ. М.: Издательский дом «Вильямс». 2007.

⁷ Голодов В. Непараметрическая регрессия [Электронный ресурс] // MachineLearning.ru : вики-портал по машинному обучению. – 2010. – Текст : электронный. – Режим доступа: URL: http://www.machinelearning.ru/wiki/index.php?title=Непараметрическая_регрессия (дата обращения: 06.04.2026).

⁸ Mingming Zhang, Zikun Yang, Liyun Liu, Dequn Zhou, Impact of renewable energy investment on carbon emissions in China - An empirical study using a nonparametric additive regression model, Science of The Total Environment, Volume 785, 2021, 147109, ISSN 0048-9697, <https://doi.org/10.1016/j.scitotenv.2021.147109>.

⁹ Alberto Caron, Gianluca Baio, Ioanna Manolopoulou, Estimating Individual Treatment Effects using Non-Parametric Regression Models: a Review, Journal of the Royal Statistical Society Series A: Statistics in Society, Volume 185, Issue 3, July 2022, Pages 1115–1149, <https://doi.org/10.1111/rssa.12824>

¹⁰ Anatolyev, Stanislav. (2009). Nonparametric regression (in Russian). Quantile. 37-52.

Таким образом, трудности возникают в условиях малых выборок, сложного распределения ошибок и наличия выбросов. В таких ситуациях стандартные параметрические методы не работают из-за нарушения предположений, а подбор гиперпараметров для ядерной регрессии становится нестабильным. Это приводит к переобучению или неоптимальной ширине окна и, как следствие, к существенным ошибкам аппроксимации. В связи с этим актуальна разработка альтернативных подходов, позволяющих получить устойчивые результаты на ограниченных и зашумленных данных.

Объектом исследования выступает процесс оценки регрессионной зависимости, а предметом — методы построения робастных оценок на основе энтропийных принципов в условиях малых выборок и нестандартного распределения ошибок. Цель работы заключается в разработке и верификации подхода к получению устойчивых регрессионных моделей без априорных предположений о структуре шума. Для её достижения решаются три задачи: реализовать модифицированный энтропийный метод оценивания; сравнить его эффективность с классическими методами ядерной регрессии на синтетических и реальных данных в сложных условиях; оценить чувствительность решения к различным уровням шума. В исследовании применяются методы математического моделирования, вычислительного эксперимента, бутстреп-оценки (.632+) и статистического тестирования гипотез. Научная значимость состоит в экспериментальном обосновании эффективности энтропийного оценивания как устойчивой альтернативы ядерной регрессии при нарушении классических предположений. Практическая значимость заключается в формировании рекомендаций по выбору метода аппроксимации для ограниченных и зашумлённых данных. Основные положения и результаты работы были апробированы на 68 конференции МФТИ и будут опубликованы в сборнике конференции¹¹.

Структура работы следующая. Первая часть посвящена обзору методов оценки регрессии с акцентом на непараметрические подходы. Во второй части приводится постановка задачи, описание данных и метрики качества. В третьей части представлен теоретический обзор методов и их реализация. В четвёртой части приведены результаты сравнения методов. В конце работы приводятся ключевые выводы исследования.

¹¹ Анфимов А. Д. Оценивание регрессионных зависимостей энтропийным методом на малых выборках с ненормальными ошибками // Материалы к 68-й научной конференции МФТИ : тез. докл. / Московский физико-технический институт (нац. исслед. ун-т). – Долгопрудный : МФТИ, [год]. – В печати.

Основная часть

1. Обзор литературы

1.1. Современное состояние области исследования непараметрических методов

Непараметрическая регрессия позволяет моделировать зависимость $Y = f(X) + \varepsilon$ без предположений о виде функции f . Непараметрические методы не предполагают конкретной формы распределения и опираются непосредственно на данные для оценки сложных зависимостей¹². Среди множества существующих подходов, описанных в работах Анатольева С.¹³ и Matias S.¹⁴, можно выделить три основных направления: ядерные методы (kernel methods), методы анализа многообразий (manifold learning) и методы копульного моделирования. Рассмотрим их подробнее.

1.1.1. Ядерное сглаживание

Ядерное сглаживание¹⁵ (Kernel Density Estimation, KDE) – это непараметрический метод оценки плотности вероятности случайной величины на основе выборки. В каждой точке вычисляется сглаженная оценка функции плотности с помощью весов, определяемых ядром и полосой пропускания (окном). Данный метод известен как ядерная оценка плотности Розенבלата — Парзена^{16 17}:

$$\widehat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right), \quad (1)$$

где x_i – элементы выборки, $K(x)$ – ядерная функция, h – полоса пропускания (окно сглаживания).

Ядро¹⁸ $K(x)$ – это непрерывная ограниченная симметричная вещественная функция с единичным интегралом. Особенности выбора ядра будут рассмотрены в отдельной главе. В рамках данного подхода выделяют несколько направлений, фокусирующихся на различных аспектах метода.

¹² Anatolyev, Stanislav. (2009). Nonparametric regression (in Russian). Quantile. 37-52.

¹³ Там же.

¹⁴ Salibian-Barrera, Matias. (2022). Robust nonparametric regression: review and practical considerations. 10.48550/arXiv.2211.08376.

¹⁵ Anatolyev, Stanislav. (2009). Nonparametric regression (in Russian). Quantile. 37-52.

¹⁶ Rosenblatt, Murray. “Remarks on Some Nonparametric Estimates of a Density Function.” *Annals of Mathematical Statistics* 27 (1956): 832-837.

¹⁷ Parzen, Emanuel (1962) On Estimation of a Probability Density Function and Mode. *The Annals of Mathematical Statistics*, 33 (3) 1065-1076 doi:10.1214/aoms/1177704472

¹⁸ Там же.

Первое направление — энтропийное оценивание. Метод ME-KDE (minimum entropy-based KDE) подробно описан в работе Jie Jiang и др.¹⁹. Он используется для сравнения моделей и выбора гиперпараметра h по принципу максимума энтропии, что позволяет снизить смещение оценки. Выбирается модель, максимизирующая функцию энтропии:

$$H(f) = - \int f(x) \ln f(x) dx \quad (2)$$

Второе направление заключается в измерении ошибки между истинной плотностью $f(x)$ и оценённой $\widehat{f}(x)$ по норме L1 и L2 соответственно:

- L1-ошибка: $\|f - \hat{f}\|_1 = \int |f(x) - \widehat{f}(x)| dx$ — более устойчива к выбросам, но хуже улавливает локальные пики;
- L2-ошибка: $\|f - \hat{f}\|_2 = \int (f(x) - \widehat{f}(x))^2 dx$ — чувствительна к выбросам, но лучше описывает локальные пики.

На практике в качестве ошибки часто используют mean integrated squared error (MISE) (3). Так как в реальных задачах истинная плотность неизвестна, используется асимптотическая оценка (AMISE), которая оптимизируется с помощью бутстрэпа²⁰, кросс-валидации²¹ или эмпирического правила Сильвермана²².

$$MISE(h) = E \left[\int (\widehat{f}_h(x) - f(x))^2 dx \right] \quad (3)$$

Третий подход — метод моментов. Он используется для подбора гиперпараметров ядра (в частности, полосы пропускания h) на основе согласования теоретических и выборочных моментов случайной величины. Подбирается такое h , при котором моменты оценки $\widehat{f}_h(x)$ близки к выборочным. Применение данного метода рассматривается в работе Bradley W. и др.²³.

¹⁹ Jie Jiang, Yu-Lin He, De-Xin Dai, Joshua Zhexue Huang, A new kernel density estimator based on the minimum entropy of data set, Information Sciences, Volume 491, 2019, Pages 223-231, ISSN 0020-0255, <https://doi.org/10.1016/j.ins.2019.04.010>.

²⁰ Miecznikowski, J. C., Wang, D., & Hutson, A. (2010). Bootstrap MISE Estimators to Obtain Bandwidth for Kernel Density Estimation. Communications in Statistics - Simulation and Computation, 39(7), 1455–1469. <https://doi.org/10.1080/03610918.2010.500108>

²¹ Mammen, E., Martínez Miranda, M. D., Nielsen, J. P., & Sperlich, S. (2011). Do-Validation for Kernel Density Estimation. Journal of the American Statistical Association, 106(494), 651–660. <https://doi.org/10.1198/jasa.2011.tm08687>

²² Silverman, B.W. (1986). Density Estimation for Statistics and Data Analysis. London: Chapman & Hall/CRC. p. 45. ISBN 978-0-412-24620-3.

²³ Wakefield, B., Lin, YX., Sarathy, R. et al. Moment-based density estimation of confidential micro-data: a computational statistics approach. Stat Comput 33, 35 (2023). <https://doi.org/10.1007/s11222-022-10203-1>

Четвертый подход — метод инвариантов (кумулянтов). Он заключается в использовании инвариантов для анализа формы плотности, построения уточнённых оценок через разложение в ряд Эджворта или Грама-Шарлье и оценки полосы пропускания. Пример применения метода описан в работе Yanhong Luo, Xu Wang и Shijie Yan²⁴.

1.1.2. Метод анализ многообразия (manifold learning)

В данном подходе²⁵ предполагается, что данные лежат на скрытом многообразии меньшей размерности, вложенном в исходное высокоразмерное пространство. Методы анализа многообразия понижают размерность данных и обнаруживают нелинейные зависимости, сохраняя геометрические свойства данных локально и глобально. Некоторые методы связаны с «ядерным трюком» (kernel trick), когда связь переменных исследуется в другом пространстве признаков. Непараметрическим данный подход считается, поскольку не предполагает фиксированной параметрической формы многообразия; структура выводится из данных с помощью локальных статистик. В рамках данной работы этот подход не рассматривается, так как он ориентирован на задачи снижения размерности, а не непосредственно на регрессию.

1.1.3. Метод перебора (копультного моделирования)

Копула²⁶ — это многомерная функция распределения, определённая на n -мерном единичном кубе $[0,1]^n$, с равномерными маргинальными распределениями. Она позволяет исследовать взаимосвязь между переменными, разделяя структурную зависимость и маргинальные распределения. Метод²⁷ заключается в аппроксимации эмпирической копулы параметрическими семействами (Гаусса, Стюдента, Архимедовыми) путем перебора. Модели аппроксимируют копулу, так как в реальных данных зависимость обычно сложна и не описывается полностью стандартными функциями.

Несмотря на использование параметрических семейств, данный подход является непараметрическим, так как отсутствуют априорные предположения о форме зависимости; подбирается наиболее подходящее эмпирическое приближение. Для оценки ошибки

²⁴ Yanhong Luo, Xu Wang, Shijie Yan, Risk assessment of photovoltaic distribution network based on adaptive kernel density estimation and cumulant method, Energy Reports, Volume 8, Supplement 13, 2022, Pages 1152-1159, ISSN 2352-4847, <https://doi.org/10.1016/j.egy.2022.08.156>.

²⁵ Столяров, Д. М. Анализ на гладких многообразиях : конспект лекций [Электронный ресурс] / Д. М. Столяров ; Санкт-Петербургский государственный университет, Факультет математики и компьютерных наук. — 14 февраля 2025. — URL: https://math-cs.spbu.ru/wp-content/uploads/2025/02/Lecture_Notes.pdf (дата обращения: 20.01.2026). — Текст : электронный.

²⁶ Благовещенский Ю. Н. Основные элементы теории копул // Прикладная эконометрика, № 2 (26), 2012. С. 113—130.

²⁷ Там же.

используются метрики, схожие с KDE (например, MISE). Как и в случае с методами многообразия, данный подход сложно применить для построения непараметрической регрессии в рамках данной работы, поэтому он не рассматривается подробно.

1.2. Текущие результаты из области оценивания регрессии

Развитие вычислительных ресурсов и рост объёмов данных стимулируют применение непараметрической регрессии в машинном обучении, медицине, экономике и финансах. В данной главе рассматриваются современные прикладные результаты использования этих методов.

В качестве примера работы в области медицины можно выделить статью Альберта Канона, Гианлуки Байо и Иоанна Манолополоу. В ней авторы рассматривают современные подходы к оценке гетерогенных и индивидуальных эффектов лечения (CATE/ITE) с использованием методов непараметрической регрессии. Такой подход позволяет убрать или уменьшить необходимость в традиционных рандомизированных экспериментах, что особенно актуально в сферах, где они невозможны. В статье используется два основных непараметрических подхода: Bayesian Additive Regression Trees (BART), а именно Bayesian Causal Forest (BCF) и мета-алгоритмы (S-, T-, X-, R-Learners). Эти методы позволили исследователям без жёстких предположений о функциональной зависимости оценить сложную связь между лечением и ковариатами. Авторы отмечают, что гибкий подход был критичным для минимизации систематических ошибок в оценках причинных эффектов и подчеркивают преимущество такого подхода перед параметрическими методами в контексте высокой размерности данных, несбалансированных групп и смешивающих факторов. Эффективность методов продемонстрирована на данных о влиянии школьных обеденных программ на здоровье детей и на синтетических наборах данных. Отмечается, что корректное применение методов требует соблюдения допущений об отсутствии скрытых смешивателей и перекрытии распределений ковариат в группах лечения и контроля.

В экономике непараметрическая регрессия применяется для анализа сложных и неизвестных зависимостей. В работе Мингминга Джанга и др.²⁸ исследуется влияние инвестиций в возобновляемую энергетику на выбросы CO₂ в Китае с помощью непараметрической аддитивной модели STIRPAT. Модель позволяет одновременно учитывать линейные эффекты известных факторов (ВВП, уровень индустриализации и т.

²⁸ Mingming Zhang, Zikun Yang, Liyun Liu, Dequn Zhou, Impact of renewable energy investment on carbon emissions in China - An empirical study using a nonparametric additive regression model, Science of The Total Environment, Volume 785, 2021, 147109, ISSN 0048-9697, <https://doi.org/10.1016/j.scitotenv.2021.147109>.

д.) и нелинейное влияние целевых переменных. Анализ выявил сложную динамику влияния инвестиций: первоначальный рост выбросов из-за инфраструктурных затрат, последующее снижение благодаря замещению ископаемого топлива и повторный рост при масштабировании из-за экологических издержек инфраструктуры. Также обнаружены нелинейные зависимости для экономического роста (монотонное увеличение выбросов) и урбанизации (кривая в форме перевёрнутой U). Авторы подчёркивают способность непараметрических методов выявлять скрытые паттерны, недоступные параметрическому анализу, и предлагают рекомендации по повышению эффективности «зелёных» инвестиций в Китае.

В финансовой сфере непараметрическая регрессия используется для прогнозирования доходности активов. В исследовании Тингтинга Ченга и др.²⁹ разработана многопериодная модель, учитывающая локально стационарные предикторы (соотношение цены к прибыли, дивидендную доходность) и оценивающая регрессию методами ядерного сглаживания. Результаты показывают, что модифицированные непараметрические модели (MA1, MA2) превосходят линейные модели, историческое среднее и методы машинного обучения по точности прогнозов. Превосходство особенно заметно в долгосрочной перспективе (3–12 месяцев) и в периоды рыночной нестабильности (например, кризис 2009 года). Модель адаптивно учитывает нелинейные связи и структурные сдвиги за счёт временной локализации. Инвестиционная стратегия, построенная на основе модели MA2, продемонстрировала высокую доходность при низком уровне риска. Авторы заключают, что непараметрическая регрессия эффективна для анализа финансовых данных благодаря гибкости и устойчивости к структурным изменениям.

Рассмотренные исследования подтверждают, что непараметрическая регрессия является эффективным инструментом для прикладных задач, требующих учёта сложных нелинейных зависимостей и адаптации к изменяющимся условиям данных.

1.3. Перспективные подходы оценивания регрессии

Большинство современных методов построения регрессии связаны с машинным обучением, поэтому множество исследований прямо или косвенно посвящены именно этой теме. Однако машинное обучение и нейросети применяются в работах по-разному.

²⁹ Cheng, Tingting and Gao, Jiti and Linton, Oliver B. and Yan, Yayi, Nonparametric Predictive Regression for Stock Return Prediction 1 (February 05, 2025). Available at SSRN: <https://ssrn.com/abstract=5126279> or <http://dx.doi.org/10.2139/ssrn.5126279>

Одним из ключевых направлений исследования являются проблемы построения регрессии в высокоразмерных пространствах. Здесь можно выделить работу Елены Брадик и др.³⁰, в которой авторы изучают современные методы в описанных выше условиях, фокусируясь на корневой p -согласованности оценок линейных функционалов (например, регрессионного наклона или среднего эффекта). В статье авторы модифицируют подходы, использующие двойное (debiased) машинное обучение и разреженные аппроксимации. Таким образом, предложенный подход позволил им оценить параметры при отсутствии знаний о структуре данных. В качестве результатов исследования авторы выделяют установление условий разреженности и гладкости (ξ_1, ξ_2) , при которых достижима скорость $O(\frac{1}{\sqrt{n}})$, и построение устойчивых к гетероскедастичности оценок через регуляризованные представители Рисса. В завершение авторы подчёркивают преимущество подобного подхода по сравнению с такими методами как debiased Lasso и series estimation, а именно высокая эффективность в условиях слабых предположениях о данных. Таким образом, данная работа обобщает непараметрические идеи и показывает, как с помощью машинного обучения можно улучшить качество регрессии в высокоразмерных пространствах, расширяя применимость метода в экономике и других сферах.

Другой подход применяется в работе Юпинг Сонга и др.³¹. В своей статье авторы фокусируются на интеграции современных методов глубокого машинного обучения с классической ядерной непараметрической регрессией. Качество моделей изучается в контексте прогнозирования высокочастотных финансовых данных, которые сложно предсказывать из-за нелинейности, высокой волатильности, долговременной памяти и частых скачков. Авторы подмечают, что обычные подходы плохо справляются с этой задачей: традиционные эконометрические модели (ARIMA, GARCH) ограничены при работе с подобными данными из-за предположений о линейности и стационарности; машинное обучение (SVM, нейросети) справляются с нелинейностью, однако не улавливают долговременную память; глубокие нейросети хорошо прогнозируют, но не интерпретируемы. В работе предлагается гибридная модель NR-LSTM, объединяющая

³⁰ Bradic, Jelena & Chernozhukov, Victor & Newey, Whitney & Zhu, Yinchu. (2019). Minimax Semiparametric Learning With Approximate Sparsity. 10.48550/arXiv.1912.12213.

³¹ Yuping Song, Chunchun Cai, Dexiang Ma, Chen Li, Modelling and forecasting high-frequency data with jumps based on a hybrid nonparametric regression and LSTM model, Expert Systems with Applications, Volume 237, Part A, 2024, 121527, ISSN 0957-4174, <https://doi.org/10.1016/j.eswa.2023.121527>.

интерпретируемость непараметрической регрессии со способностью глубокой нейросети улавливать долговременные эффекты и краткосрочные аномалии. В статье непараметрическая регрессия используется для моделирования тренда, в то время как глубокая нейросеть корректирует остатки, повышая общую точность прогноза. Полученная модель эмпирически проверялась на разнообразных финансовых данных (CSI 300, FTSE 100, S&P 500) и показала значительное улучшение по сравнению с другими подходами по метрике средней абсолютной ошибки (MAE), демонстрируя устойчивость и универсальность. Таким образом, данная работа подчеркивает перспективность гибридных методов, так как они позволяют использовать сильные стороны как традиционных статистических подходов, так и современных алгоритмов ИИ для решения задач в условиях больших данных и неопределённости.

Важной в данном контексте является статья Minshuo Chen и др.³². В ней авторы проводят теоретический анализ построения непараметрической регрессии на низкоразмерных многообразиях с помощью глубоких нейросетей с функцией активации ReLU. В точной постановке задачи исследуется восстановление функции f_0 , заданной на d мерном римановом многообразии M , вложенным в пространство $\mathbb{R}^D$, по зашумлённым данным $y_i = f_0(x_i) + \xi_i$, где ξ_i – независимый субгауссовский шум. В работе авторы доказывают, что ReLU-сети могут эффективно аппроксимировать любую гладкую или гёльдерову функцию на многообразии с нужной погрешностью. Однако самое главное, что полученная скорость сходимости для такого метода построения непараметрической регрессии зависит от внутренней размерности d , то есть сложности самой зависимости, а не от размерности внешнего пространства D . В заключение, авторы продемонстрировали на примере задачи обработки картинок из датасета ImageNet, что классическими подходами практически невозможно получить высокую точность из-за проклятья размерности, в то время как предложенный метод вполне осуществим. Работа развивает идеи исследований Schmidt-Hieber (2019) и Nakada & Imaizumi (2020) об адаптации нейросетей к свойствам данных и демонстрирует преимущество подходов на основе глубоких нейросетей перед классическими подходами в задачах с высокоразмерными, но структурированными данными, где моделируемые зависимости гораздо проще пространства, в котором они находятся.

³² Chen, Minshuo & Jiang, Haoming & Liao, Wenjing & Zhao, Tuo. (2022). Nonparametric regression on low-dimensional manifolds using deep ReLU networks: function approximation and statistical recovery. *Information and Inference: A Journal of the IMA*. 11. 10.1093/imaiai/iaac001.

Несмотря на популярность нейросетового подхода также остаются модели, фокусирующиеся на модификации классических подходов. Особенно актуальной в контексте построения непараметрической регрессии является статья Taha Hussein Ali и др.³³. В своей работе авторы представляют новый метод оценки параметра ширины окна (полосы пропускания) в непараметрической регрессии Надарая-Ватсона. В то время как классические подходы предлагают использовать фиксированную или переменную (локально оптимальную) ширину окна, авторы предлагают улучшенный подход, основанный на универсальном пороговом уровне, вычисленном с помощью вейвлета Добеши. Для оценки шума используется медиана абсолютных отклонений (MAD), а порог определяется как $d_i = \hat{\sigma}_{MAD} \sqrt{2 \log N}$, где N – количество вейвлет коэффициентов. Предложенный подход авторы сравнивали с методами, которые основаны на геометрическом среднем, арифметическом среднем, размахе и медиане, на синтетических данных (размеры выборок – 32, 64 и 128) и реальных (извержения гейзера Old Faithful). По результатам оценки улучшенный подход показал наименьшую MSE по сравнению с классическими методами при всех объемах выборки и значениях начальной полосы пропускания на всех датасетах. Таким образом, данный метод является очень перспективным, особенно на маленьких выборках – он адаптивно настраивает ширину окна в регрессии Надарая-Ватсона, тем самым улучшая прогнозную способность модели. Более того, авторы подчеркивают, что использование других вейвлетов и пороговых стратегий (например, кросс-валидации) может ещё улучшить метод под конкретную задачу.

Другим примером современного исследования классических методов является работа Xin Bing, Xin He, Chao Wang³⁴. В ней авторы рассматривают ядерную гребневую непараметрическую регрессию (KRR) и доказывают её эффективность в условиях, когда исходные данные зашумлены. Эта задача особенно актуальна в текущем ландшафте высокоразмерных и зашумлённых данных, когда в моделях используются не сами признаки, а скрытые факторы из них, например полученные методом опорных векторов. В статье авторы предполагают, что данные X связаны со скрытыми факторами Z через функцию g (например, $X = g(Z) + \text{шум}$). Вместо истинных факторов используется их оценка $\hat{Z}$, из данных X , полученная с помощью ядерной регрессии. Далее авторы исследуют ошибку предсказания $\hat{Z}$ при таком подходе. В результате в работе доказывается

³³ Taha Hussein Ali, Heyam Abd Al-Majeed Hayawi & Delshad Shaker Ismael Botani (2021): Estimation of the bandwidth parameter in Nadaraya-Watson kernel non-parametric regression based on universal threshold level, Communications in Statistics - Simulation and Computation, DOI: 10.1080/03610918.2021.1884719

³⁴ Xin Bing, Xin He, Chao Wang, 2025, Kernel Ridge Regression with Predicted Feature Inputs and Applications to Factor-Based Nonparametric Regression, <https://doi.org/10.48550/arXiv.2505.20022>

теоретическая гарантия точности предложенного метода и показывается, что он достигает оптимальной скорости сходимости даже при наличии ошибок в данных. Таким образом, данное исследование подтверждает устойчивость KRR к высокой размерности и шуму в данных, тем самым показывая её преимущество перед другими методами, которые сталкиваются с проклятием размерности и ограничениями на наблюдаемые признаки.

2. Постановка задачи, генерация и сбор данных

2.1. Формальная постановка задачи оценки одномерной регрессии

Цель задачи – восстановить неизвестную функциональную зависимость $g(x)$ между одной независимой переменной X (регрессор) и зависимой переменной Y на основе конечной выборки наблюдений, чтобы либо минимизировать ошибку предсказаний для новых значений x и/или интерпретировать структуру связи Y и X .

Пусть имеется обучающая выборка данных $\{(x_i, y_i)\}_{i=1}^n$, где $x_i \in X \subseteq R^n$ – наблюдения регрессора, $y_i \in R$ – наблюдения зависимой переменной, n – размер выборки. Также предполагается следующая структурная модель:

$$y_i = g(x_i) + \varepsilon_i, i = 1, \dots, n, \quad (4)$$

где $g(x) = E(Y|X = x)$ – истинная функция регрессии (неизвестна, предполагается полиномиальная зависимость), ε_i – случайная ошибка с существующими конечными моментами первого и второго порядков, такие что $E(\varepsilon_i|x_i) < \infty, D(\varepsilon_i|x_i) < \infty$.

Требуется найти оценку функции регрессии $\widehat{g(x)}$, минимизирующую заданную функцию потерь на обучающей выборке и обобщающую на новые $x \notin \{x_1, \dots, x_n\}$. Функция потерь зависит от выбора метода и подхода в рамках него и будет описана в соответствующих разделах обзоров выбранных методов.

2.2. Общее описание датасетов

Для оценки качества методов, а также их сравнения в данной работе используется ряд синтетических наборов данных, каждый из которых содержит $n = 30$ наблюдений. Для получения достоверных оценок качества методы оцениваются несколько раз на одном типе датасета, и на каждой итерации оценивания датасет нужного типа генерируется заново. Реплицируемость результатов контролируется с помощью seed – они указаны в соответствующих разделах практической части. Генерация происходит в несколько этапов:

- 1) Выбирается 30 точек, равномерно расположенных на отрезке от 0 до 1;
- 2) Для каждой точки рассчитывается значение истинной функции регрессии на основе одной из моделей генерации. Модели генерации представлены в разделе 2.2.3;
- 3) К полученному значению прибавляется сгенерированная ошибка. Генерация ошибок обсуждается в разделе 2.2.2.

Исключением является модель генерации, основанная на смеси нормальных распределений (см. раздел 2.2.3).

Для оценки качества работы моделей на реальных данных используется известный датасет, содержащий извержения гейзера Старый Служака. Датасет представлен в виде таблицы с 272 наблюдениями по времени извержения в минутах и времени ожидания следующего извержения в минутах. Он неоднократно использовался в исследованиях, посвящённых оценке непараметрической регрессии³⁵. На рис. 1 видно, что в среднем есть положительная зависимость между переменными. Извержения можно условно разделить на два типа – короткие с маленьким временем ожидания и длинные с большим временем ожидания.




Рис. 1. Зависимость между продолжительностью извержения и временем ожидания, Гейзер "Старый Служака" (Озеро Йеллоустон).

³⁵ Taha Hussein Ali, Heyam Abd Al-Majeed Hayawi & Delshad Shaker Ismael Botani (2021): Estimation of the bandwidth parameter in Nadaraya-Watson kernel non-parametric regression based on universal threshold level, Communications in Statistics - Simulation and Computation, DOI: 10.1080/03610918.2021.1884719




Рис. 2. Распределение данных по извержению гейзера.

2.2.1. Обоснование размера выборки

Маленькое количество наблюдений ($n = 30$) в наборе обусловлено рядом причин. Во-первых, в рамках данного исследования я фокусируюсь на оценке методов в сложных условиях, когда данных мало и ошибки распределены по разным законам. Именно в таких условиях используемые подходы имеют теоретическое преимущество по сравнению с классическими методами вроде МНК, которые показывают более низкую эффективность из-за нарушения предположений о нормальности ошибок. В частности, предлагаемый в данной работе метод энтропийного оценивания с жесткими балансовыми ограничениями изначально разработан для работы с малыми выборками и асимметричными/тяжелохвостыми распределениями ошибок, что делает его робастным в экстремальных сценариях. Таким образом, можно не только протестировать его в подходящих условиях, но и смоделировать реальные задачи, где сбор больших объёмов данных затруднён, например, исследование редких экономических событий.

Во-вторых, $n = 30$ выбран как компромисс вычислительной сложностью и статистической осуществимостью. С одной стороны, этот размер достаточен для применения базовых методов кросс-валидации и оценки дисперсии коэффициентов³⁶. С другой стороны, это граница применимости ряда важных асимптотических приближений, таких как ЦПТ³⁷. Такой подход позволяет нам оценить модели в “неудобных” для классических методов условиях, о чем упоминалось выше.

³⁶ Efron B. Estimating the error rate of a prediction rule: improvement on cross-validation //Journal of the American statistical association. – 1983. – Т. 78. – №. 382. – С. 316-331.

³⁷ van der Vaart, A. W. (1998). Asymptotic Statistics: U-Statistics. <https://doi.org/10.1017/CBO9780511802256.013>

В-третьих, основной метод, предлагаемый в данной статье, а именно энтропийное оценивание с жесткими балансовыми ограничениями, вычислительно требователен, так как требует решения системы уравнений размерности n (см. главу ВСТАВИТЬ ГЛАВУ). Поэтому с точки зрения временных затрат использование больших наборов данных было бы непрактичным.

2.2.2. Генерация ошибок

Для каждой точки независимо генерируется ошибка. Ошибки берутся из разных распределений, но параметры подбираются так, чтобы матожидание ошибки было нулевым, а дисперсия единичной, т.е. $E(\varepsilon_i) = 0, D(\varepsilon_i) = 1$. Таким образом, для 30 точек в каждом датасете генерируется соответственно 30 ошибок из разных распределений. Ошибки берутся в случайном порядке. Используются следующие распределения:

1) Группа 1: Классические симметричные распределения

- Нормальное — базовое распределение для сравнения;
- Логистическое — похоже на нормальное, но с более тяжелыми хвостами;
- Распределение Лапласа — остроконечное с экспоненциальными хвостами;
- Гиперболический секанс — интересная форма с более легкими хвостами, чем у нормального;
- Обобщенное нормальное ($\beta=0.5$) — очень остроконечное распределение.

2) Группа 2: Распределения с тяжелыми хвостами

- Распределение Стьюдента ($df=3$) — очень тяжелые хвосты;
- Распределение Стьюдента ($df=30$) — почти нормальное, но с чуть более тяжелыми хвостами;
- Двойное Вейбулла ($c=1.5$) — асимметричное с тяжелыми хвостами;
- Двойное Вейбулла ($c=3.5$) — почти симметричное с легкими хвостами;
- Устойчивое ($\alpha=1.8$) — распределение с бесконечной дисперсией при $\alpha \leq 2$, но для $\alpha=1.8$ можно настроить конечную дисперсию.

3) Группа 3: Распределения экстремальных значений

- Гумбель для максимумов — распределение максимумов;
- Гумбель для минимумов — распределение минимумов;
- Обобщенное экстремальное ($c=0.5$) — гибкое распределение для экстремумов;

- Обобщенное экстремальное ($c=-0.5$) — другая форма для экстремумов;
- Распределение Мюллера — асимметричное распределение для энергетических измерений.

4) Группа 4: Скошенные (асимметричные) распределения

- Скошенное нормальное ($a=5$) — сильная правая асимметрия;
- Скошенное нормальное ($a=-5$) — сильная левая асимметрия;
- Нецентральное t ($df=10$, $nc=3$) — асимметричное распределение из статистики;
- Экспоненциально модифицированное нормальное ($K=1$) — правая асимметрия;
- Экспоненциально модифицированное нормальное ($K=2$) — более сильная правая асимметрия.

5) Группа 5: Специальные распределения

- Распределение Джонсона SU ($a=2$, $b=1$) — гибкое семейство распределений;
- Распределение Джонсона SU ($a=0.5$, $b=2$) — другая конфигурация для разнообразия;
- Обобщенное логистическое ($c=0.5$) — похоже на логистическое, но более гибкое;
- Обобщенное логистическое ($c=2.0$) — другая форма обобщенного логистического;
- Распределение Тьюки ($\lambda=0.5$) — гибкое распределение, переходящее между различными формами;
- Распределение Тьюки ($\lambda=-0.5$) — другая конфигурация для асимметрии.

6) Группа 6: Менее известные, но интересные распределения

- R-распределение ($c=0.5$) — семейство распределений с разной степенью эксцесса;
- R-распределение ($c=2.0$) — другая конфигурация с более легкими хвостами;
- Степенное нормальное ($c=0.3$) — преобразованное нормальное распределение;
- Степенное нормальное ($c=0.8$) — другая степень преобразования.

Все распределения соответствуют следующим требованиям:

- Определены на всей числовой оси $(-\infty, +\infty)$;
- Параметры подобраны так, что $E(\varepsilon_i) = 0, D(\varepsilon_i) = 1$;
- Достаточно сильно различаются друг от друга;
- Реализованы в одной библиотеке и контролируются одним seed (для удобства и реплицируемости).

Более подробно описание используемых распределений и их параметров представлено в Приложении 1.

2.2.3. Описание моделей генерации

2.2.3.1. Полиномиальная регрессия

Для генерации зависимости в данных используются полиномы до 6 степени включительно, т.е.

$$g(x) = \alpha_1 + \alpha_2 x + \dots + \alpha_i x^i, \quad (5)$$

где i — степень полинома.

Фактический процесс генерации для каждого коэффициента выглядит следующим образом:

- 1) Генерируется нормальная величина $\mathcal{N}(0, 1)$;
- 2) Она умножается на фактор масштаба k_1 и фактор смещения k_2 ;
- 3) Полученное число случайно умножается либо на 1, либо на -1.

Так как масштаб ошибок не меняется, то факторы k_1 и k_2 по сути определяют влияние ошибок. В рамках данного исследования они контролируемо подбираются по метрике относительного уровня шума:

$$\eta = \frac{\sigma_\varepsilon}{\sigma_{g(x)}}, \quad (6)$$

где σ_ε — стандартное отклонение ошибок, $\sigma_{g(x)}$ — стандартное отклонение истинных точек регрессии.

Эта метрика широко используется при генерации данных для непараметрической регрессии в научной литературе^{38 39 40}. В качестве умеренного уровня обычно⁴¹ выбирается η из диапазона от 0.2 до 0.4. Относительный уровень шума взаимно-однозначно конвертируется в R^2 исходя из определений по формуле:

$$R^2 = \frac{1}{1 + \eta^2} \Leftrightarrow \eta = \sqrt{\frac{1}{R^2} - 1}. \quad (7)$$

Для сравнения качества оценок методов в разных условиях генерируется выборки со следующими:

- $\eta = 0.229416 \Leftrightarrow R^2 = 0.95$ – шум почти не мешает восстановлению структуры;
- $\eta = 0.333333 \Leftrightarrow R^2 = 0.90$ – баланс между структурой и шумом;
- $\eta = 0.5 \Leftrightarrow R^2 = 0.8$ – шум существенно затрудняет восстановление

Таким образом общий процесс генерации для выбранного диапазона и степени выглядит следующим образом:

- 1) Генерируются ошибки как описано в главе 2.2.2.;
- 2) На вход идёт заранее определённое η ;
- 3) Выбираются факторы k_1 и k_2 , описанные выше. Для того, чтобы форма полиномов дополнительно различалась, факторы генерируются случайно как

$$k_i = 0.8 + 4.2 \cdot U(0,1), i = 1, 2 \quad (7)$$

где $U(0,1)$ – случайная величина, равномерно распределённая на отрезке $[0, 1]$. Случайность контролируется seed;

- 4) Наконец, чтобы достичь требуемого относительного уровня шума, значения функции дополнительно корректируются по формуле:

$$y_{true\ final} = y_{true\ base} \cdot \frac{\sigma_{errors}}{\eta_{target}} \cdot \frac{1}{\sigma_{base}}, \quad (8)$$

где $y_{true\ base}$ – изначально сгенерированные точки, σ_{errors} – выборочное стандартное отклонение сгенерированных ошибок, η_{target} – выбранный для

³⁸ Loader C. Local Regression and Likelihood / C. Loader. — New York : Springer, 1999. — 308 p. — ISBN 0-387-98775-6.

³⁹ Ruppert D. Semiparametric Regression / D. Ruppert, M. P. Wand, R. J. Carroll. — Cambridge : Cambridge University Press, 2003. — 386 p. — ISBN 0-521-78012-8.

⁴⁰ Härdle W. Applied Nonparametric Regression / W. Härdle. — Cambridge : Cambridge University Press, 1990. — 334 p. — ISBN 0-521-36985-8

⁴¹ Fan J. Local Polynomial Modelling and Its Applications / J. Fan, I. Gijbels. — London : Chapman & Hall, 1996. — 396 p. — ISBN 0-412-98321-4.

данной генерации уровень относительного шума, σ_{base} – выборочное стандартное отклонение $y_{true_{base}}$. Суть преобразования заключается в домножении всех коэффициентов полинома на нужное число, чтобы в точности достичь требуемой дисперсии.

Всего генерируется 300 датасетов каждого вида, т.е. для каждой комбинации степени и уровня шума генерируется 300 выборок.

2.2.3.2. Двумерная смесь нормальных распределений

Также исследуется модель двухкомпонентной смеси двумерных нормальных величин. В этом случае двумерный вектор (X, Y) имеет распределение смеси:

$$p(x, y) = \pi \cdot \mathcal{N} \left(\begin{bmatrix} x \\ y \end{bmatrix}; \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1 \right) + (1 - \pi) \cdot \mathcal{N} \left(\begin{bmatrix} x \\ y \end{bmatrix}; \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2 \right), \quad (6)$$

где $\pi \in (0,1)$ – вес первого компонента, $\boldsymbol{\mu}_k = \begin{bmatrix} \mu_{kx} \\ \mu_{ky} \end{bmatrix}$ – вектор средних для компонента k ,

$\boldsymbol{\Sigma}_k = \begin{bmatrix} \sigma_{kx}^2 & \sigma_{kxy} \\ \sigma_{kxy} & \sigma_{ky}^2 \end{bmatrix}$ – ковариационная матрица для компонента k . В данной работе взяты

следующие параметры компонент для генерации: $\pi = 0.8$, $\boldsymbol{\mu}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$, $\boldsymbol{\mu}_2 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$, $\boldsymbol{\Sigma}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$,

$\boldsymbol{\Sigma}_2 = \begin{bmatrix} 9 & 0 \\ 0 & 9 \end{bmatrix}$.

В Приложении 2 представлен вывод, показывающий, что условное матожидание $E(y | X = x)$ можно представить в виде регрессии (4). Таким образом, данная модель генерации подходит для оценки качества и сравнения моделей в рамках поставленной задачи. Кроме того, ошибки в данном случае будут удовлетворять нашим требованиям – они не будут одинаково распределены и будут иметь при фиксированном x_i сложную зависимую структуру внутри одного наблюдения.

Для этой модели генерация отличается и, кроме того, дополнительно разделена на два случая:

- 1) Детерминировано генерируется 24 точки из первого распределения и 6 из второго, после чего они случайно перемешиваются. Этот подход используется, чтобы оценить базовую погрешность метода, изолировав её от шума в данных.
- 2) Сначала случайно согласно бернуллиевскому распределению с $p = 0.8$ выбирается компонента, после чего из соответствующего распределения генерируется точка. В

этом случае имитируются более реалистичные условия и исследуется робастность метода к вариациям в данных.

2.3. Критерии оценки качества

В данной главе приведены выбранные в рамках исследования метрики оценки качества полученных регрессий, а также описан общий процесс их оценки.

2.3.1. Для синтетических датасетов

Особенностью синтетических данных является то, что известна истинная функция регрессии. Это позволяет довольно точно оценить фактическое качество оценки регрессии. Таким образом, главной метрикой в данном случае выбрана интегральная среднеквадратичная ошибка – стандартный выбор для количественной оценки близости оценённой функции $\widehat{g(x)}$ к истинной $g(x)$:

$$IMSE = \frac{1}{x_{max} - x_{min}} \int_{x_{min}}^{x_{max}} (\widehat{g(x)} - g(x))^2 dx, \quad (7)$$

где $[x_{min}, x_{max}] = [0, 1]$ для полиномиальных регрессий и $[x_{min}, x_{max}] = [-1.5, 6.5]$ для смесей. Выбранный интервал для исследуемых смесей покрывает приблизительно 95% вероятностной массы смеси распределений, так как

$$\begin{aligned} &P(X < -1.5) + P(X > 6.5) \\ &= 0.8 \cdot \left(\Phi\left(\frac{-1.5 - 1}{1}\right) + 1 - \Phi\left(\frac{6.5 - 1}{1}\right) \right) + 0.2 \\ &\cdot \left(\Phi\left(\frac{-1.5 - 3}{3}\right) + 1 - \Phi\left(\frac{6.5 - 3}{3}\right) \right) \approx 95.73\%, \end{aligned}$$

где $\Phi(x)$ – функция Лапласа.

Кроме того, используются две дополнительные метрики:

$$MAE = \frac{1}{x_{max} - x_{min}} \int_{x_{min}}^{x_{max}} |\widehat{g(x)} - g(x)| dx, \quad (8)$$

$$MaxErr = \max_{[x_{min}, x_{max}]} |\widehat{g(x)} - g(x)|. \quad (9)$$

Интегральная средняя абсолютная ошибка MAE дополняет $IMSE$, так как она более робастна к экстремальным ошибкам в выборках и показывает типичное отклонение в интерпретируемом виде. Максимальная абсолютная ошибка $MaxErr$ показывает, насколько велики ошибки в критических зонах, где метод терпит неудачу.

Интегральные ошибки вычисляются на фиксированном интервале $[x_{min}, x_{max}]$ методом адаптивной квадратуры (алгоритм QUADPACK⁴²), реализованным в SciPy (SciPy⁴³ quad) $MaxErr$ вычисляется методом ограниченной оптимизации (scipy.optimize.minimize_scalar с методом 'bounded'). Все метрики считаются с абсолютной точностью с абсолютной точностью 10^{-6} . Она пренебрежимо мала по сравнению со статистической вариацией оценок метрик между итерациями (см. практическую часть). Такой подход обеспечивает воспроизводимость оценок и исключает смещение из-за выбора сетки. Однако результат расчёта дополнительно сравнивается с дискретными аналогами метрик, рассчитанных на сетке из 1000 точек, для контроля возможных артефактов интегрирования. Для контроля FWER (family wise error rate) используется поправка Бонферрони⁴⁴.

2.3.2. Для реальных данных

Для набора данных по извержениям гейзера Старый Служак, так как истинная функция неизвестна, используются метрики аналогичные прошлым, но подходящие под реальные данные:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\widehat{g(x_i)} - g(x_i))^2}, \quad (10)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |\widehat{g(x_i)} - g(x_i)|, \quad (11)$$

$$MaxErr = \max_i |\widehat{g(x_i)} - g(x_i)|. \quad (12)$$

Для получения более точной оценки качества метрики вычисляются усреднением по k-fold кросс-валидации⁴⁵. Данные разбиваются на k частей – на k-1 обучается модель, а на k-ом фолде замеряется качество. После тестирования на k фолдах метрика усредняется. В соответствии со стандартной практикой⁴⁶ для реального датасета в данной работе используется k=5.

⁴² Piessens R. и др. Quadpack. : Springer Berlin Heidelberg, 1983.

⁴³ Virtanen, P. et al., 2020. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. Nature Methods, 17, pp.261–272.

⁴⁴ Bonferroni, C. E., Teoria statistica delle classi e calcolo delle probabilità, Pubblicazioni del R Istituto Superiore di Scienze Economiche e Commerciali di Firenze 1936.

⁴⁵ Analyzing Microarray Gene Expression Data. Wiley Series in Probability and Statistics. Wiley. 2004. doi:10.1002/047172842X. ISBN 978-0-471-22616-1.

⁴⁶ Там же.

3. Обзор используемых методов

В данной главе подробно описаны используемые методы оценки регрессии.

3.1. Ядерное сглаживание

3.1.1. Обзор метода

Данный подход уже рассматривался в главе, посвящённой непараметрическим подходам, поэтому этой главе мы остановимся лишь на ключевых аспектах применения данного метода в контексте оценки непараметрической регрессии. Впервые данный метод оценки функции плотности случайной величины был предложен в работе М. Розенблата⁴⁷ и доработан в исследовании Е. Парзена⁴⁸, однако в дальнейшем был многократно модифицирован. В задаче непараметрической регрессии полученная оценка плотности используется для вычисления последовательности ядерных весов, которые были предложены в работах Надарая⁴⁹ и Ватсона⁵⁰:

$$W_{ni}(x) = \frac{K_{h_n}(x-x_i)}{\hat{f}_{h_n}(x)}, \quad (4)$$

где ширина окна $h = h_n$ зависит от объёма выборки. В тех же работах предлагается использовать данную весовую схему для оценки условного математического ожидания $E(y|x)$, то есть непараметрической регрессии по формуле, называемой оценкой Надарая-Ватсона:

$$\widehat{g}_h(x) = \frac{\frac{1}{n} \sum_{i=1}^n y_i K_{h_n}(x-x_i)}{\frac{1}{n} \sum_{i=1}^n K_{h_n}(x-x_i)}, \quad (5)$$

Как уже упоминалось ранее, основной задачей в рамках данного подхода является подбор полосы пропускания h . Чаще всего в качестве критерия оптимальности выбирают ожидаемую функцию потерь L_2 , а именно MISE (3). Однако так как истинная плотность не известна на практике используются автоматические, основывающиеся на данных методы подбора h . Наиболее эффективными в этой сфере считаются подходы, использующие

⁴⁷ Rosenblatt M. Remarks on Some Nonparametric Estimates of a Density Function // The Annals of Mathematical Statistics. — 1956. — Т. 27, вып. 3. — doi:10.1214/aoms/1177728190.

⁴⁸ Parzen, Emanuel (1962) On Estimation of a Probability Density Function and Mode. The Annals of Mathematical Statistics, 33 (3) 1065-1076 doi:10.1214/aoms/1177704472

⁴⁹ Nadaraya, E. A. On Estimating Regression // Theory of Probability and its Applications: journal. — 1964. — Vol. 9, no. 1. — P. 141—142. — doi:10.1137/1109020

⁵⁰ Watson, G. S. Smooth regression analysis // Sankhyā: The Indian Journal of Statistics, Series A. — 1964. — Т. 26, № 4. — С. 359—372. — JSTOR 25049340

подключаемые выборочные функции^{51 52} или кросс-валидацию^{53 54 55}. Также можно выделить бутстраповские методы выбора ширины окна, например, как в работе Faraway, Jhun⁵⁶, однако их недостатком является случайность целевой функции, которая приводит к вычислительным сложностям. Наконец, существуют эвристические правила подбора, в частности самое популярное – если используется гауссово ядро, и истинная плотность предполагается нормальной, то используется эмпирическое правило Сильвермана⁵⁷ для оценки h по формуле:

$$h = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1,06\hat{\sigma}n^{-\frac{1}{5}}, \quad (6)$$

где n – размер выборки, $\hat{\sigma}$ – выборочное среднеквадратичное отклонение. На практике с осторожностью данное правило применяют даже когда истинная плотность ненормальная, например, в качестве первоначального приближения h .

3.1.2. Функции ядра

Функция ядра $K(x)$ определяет веса наблюдений, их релевантность для оценки плотности в конкретной точке, поэтому несомненно является важным гиперпараметром метода. Ядро должно удовлетворять следующим условиям⁵⁸:

1. $K(x) \geq 0$ (неотрицательность);
2. $\int_{-\infty}^{+\infty} K(x)dx = 1$ (нормировка);
3. $\int_{-\infty}^{+\infty} xK(x)dx = 0$ (симметричность и центрированность);
4. $\int_{-\infty}^{+\infty} x^2K(x)dx < \infty$ (конечная дисперсия).

⁵¹ Botev Z.I., Grotowski J.F., Kroese D.P. Kernel density estimation via diffusion // Annals of Statistics. — 2010. — Т. 38, вып. 5. — doi:10.1214/10-AOS799. — arXiv:1011.2602.

⁵² Sheather S.J., Jones M.C. A reliable data-based bandwidth selection method for kernel density estimation // Journal of the Royal Statistical Society, Series B. — 1991. — Т. 53, вып. 3. — JSTOR 2345597.

⁵³ Rudemo M. Empirical choice of histograms and kernel density estimators // Scandinavian Journal of Statistics. — 1982. — Т. 9, вып. 2. — JSTOR 4615859.

⁵⁴ Bowman A.W. An alternative method of cross-validation for the smoothing of density estimates // Biometrika. — 1984. — Т. 71, вып. 2. — doi:10.1093/biomet/71.2.353.

⁵⁵ Hall P., Marron J.S., Park B.U. Smoothed cross-validation // Probability Theory and Related Fields. — 1992. — Т. 92. — С. 1–20. — doi:10.1007/BF01205233.

⁵⁶ Faraway, J., M. Jhun Bootstrap choice of bandwidth for density estimation. Journal of the American Statistical Association 85. — 1990. — С. 1119–1122.

⁵⁷ Silverman B.W. Density Estimation for Statistics and Data Analysis. — London: Chapman & Hall/CRC, 1986. — ISBN 0-412-24620-1.

⁵⁸ Watson, G. S. Smooth regression analysis // Sankhyā: The Indian Journal of Statistics, Series A. — 1964. — Т. 26, № 4. — С. 359–372. — JSTOR 25049340

Существует несколько основных ядер, каждое из которых имеет свои особенности. В данном разделе мы рассмотрим только ядра, наиболее часто применяемые на практике⁵⁹.

3.1.2.1. Гауссово ядро⁶⁰

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \quad (7)$$

Достоинства: бесконечно дифференцируемая функция, даёт аналогичные свойства оценке плотности. Как следствие предыдущего пункта, не имеет резких границ, то есть при оценке используется информация из всех наблюдений.

Недостатки: на больших выборках вычислительно дорогая из-за расчёта экспоненты, теоретически неоптимальна по критерию MISE⁶¹ и склонна к лишнему сглаживанию функции плотности из-за использования всех наблюдений.

Стоит отметить, что несмотря на недостатки гауссово ядро на практике работает почти так же хорошо, как оптимальные ядра, и поэтому широко используется.

3.1.2.2. Ядро Епанечникова⁶²

$$K(x) = \frac{3}{4} (1 - x^2) \cdot I_{\{|x| < 1\}} \quad (8)$$

Достоинства: теоретически оптимально по критерию MISE среди всех ядер с конечной схемой взвешивания и благодаря конечному взвешиванию быстрее вычисляется.

Недостатки: имеет резкие, недифференцируемые границы, из-за чего производная получается негладкой. На практике данное ядро даёт результат, визуально близкий к применению гауссова ядра.

3.1.2.3. Равномерное (прямоугольное) ядро

$$K(x) = \frac{1}{2} \cdot I_{\{|x| < 1\}} \quad (9)$$

Достоинства: вычислительно самое простое ядро.

Недостатки: негладкая оценка плотности, плохая сходимость по критерию MISE, очень чувствительна к выбору ширины окна.

⁵⁹ Wand, Matt P. and M. Chris Jones. “Kernel Smoothing.” (1995).

⁶⁰ Silverman B.W. Density Estimation for Statistics and Data Analysis. — London: Chapman & Hall/CRC, 1986. — ISBN 0-412-24620-1.

⁶¹ Wand, Matt P. and M. Chris Jones. “Kernel Smoothing.” (1995).

⁶² Epanechnikov, V. A. (1969). Non-parametric estimation of a multivariate probability density. Theory of Probability & Its Applications, 14(1), 153–158

Несмотря на недостатки, данный метод иногда применяется в качестве бейзлайна или основы для других методов.

3.1.2.4. Треугольное ядро

$$K(x) = (1 - |x|) \cdot I_{\{|x| < 1\}} \quad (10)$$

Данное ядро имеет преимущества и недостатки аналогичные равномерному, за исключением немного более гладкой функции.

3.1.2.5. Квартичное ядро (Биквадратное)

$$K(x) = \frac{15}{16} (1 - x^2)^2 \cdot I_{\{|x| < 1\}} \quad (11)$$

Модификация ядра Епанечникова – вычислительно более сложное и уже не оптимально по MISE, но дифференцируемо один раз.

3.1.2.6. Трикватратное ядро

$$K(x) = \frac{35}{32} (1 - x^2)^3 \cdot I_{\{|x| < 1\}} \quad (12)$$

Следующая модификация ядра Епанечникова, дифференцируемая уже два раза. Широко используется в методах оценки локальной регрессии.

В заключение обзора стоит отметить, что на практике выбор ядерных функций влияет на точность оценки значительно меньше, чем корректный подбор оптимальной ширины окна.

3.1.3. Преимущества

Как и у в случае других непараметрических методов, отсутствие предположений о функции регрессии позволяет адаптироваться у сложным, нелинейным зависимостям. Среди всех представленных данный метод является одним из самых простых и интуитивно понятных – чем ближе наблюдение, тем она важнее для данной точки, и тем больше её вес.

В исследованиях Надарая и Ватсона, упоминавшихся выше, также доказывается, что данная оценка сходится по вероятности к истинному математическому ожиданию при стандартных условиях гладкости. Она асимптотически нормальна, что позволяет строить доверительные интервалы. Кроме того, при использовании ограниченных ядер, например ядра Епанечникова, оценка становится устойчивой к выбросам и аномалиям вне окна.

3.1.4. Ограничения метода

Из схемы взвешивания следует, что при ядерном сглаживании возникает систематическое смещение на границах данных⁶³, так как с какой-то стороны становится слишком мало наблюдений, либо они не имеются вовсе. Например, если на краю регрессия возрастает, то оценка будет занижать фактическое значение. Для решения этой проблемы иногда применяется локально полиномиальная регрессия, в самом простом случае локально линейная.

Не менее важной проблемой является сильная чувствительность оценки к выбору полосы пропускания. Слишком высокие значения приводят к недосглаживанию, то есть переобучению, в то время как слишком низкие, наоборот, приводят к сверхсглаживанию и слишком гладкой форме кривой. Hardle в своей книге⁶⁴ разложил MSE на квадрат смещения и дисперсию и доказал, что оптимальная ширина окна должна балансировать их. В теории для каждой точки существует оптимальная ширина окна⁶⁵, однако проблема заключается в том, что она зависит от функции плотности и её производных, то есть того, что требуется оценить. Кроме того, даже при наличии такой возможности требовалось бы непараметрически оценить все эти параметры для каждой точки, что с вычислительной точки зрения слишком затратно. Именно поэтому на практике чаще всего используется глобально оптимальная ширина окна, несмотря на её недостатки. Однако стоит отметить, что есть исследования посвящённые области адаптивных ядерных оценок^{66 67}, позволяющим ширине окна меняться в точке. Их известным недостатком является введение ложного шума в оценку плотности.

Как и многие другие методы основанные на схемах взвешивания данный метод сильно страдает от проклятья размерности. В частности, Scott в своей книге⁶⁸ показывает, что в многомерном случае ($X \in \mathbb{R}^d$) скорость сходимости выражается как $n^{-\frac{4}{4+d}}$. Таким образом, при увеличении размерности для точной оценки требуется экспоненциально больше данных.

⁶³ Fan, J. (1996). Local Polynomial Modelling and Its Applications: Monographs on Statistics and Applied Probability 66 (1st ed.). Routledge. <https://doi.org/10.1201/9780203748725>

⁶⁴ Applied Nonparametric Regression W. Härdle Cambridge University Press, 1990. Econometric Theory. 8. 413-419. 10.1017/S0266466600013025.

⁶⁵ Anatolyev, Stanislav. (2009). Nonparametric regression (in Russian). Quantile. 37-52.

⁶⁶ Abramson, I.S. On bandwidth variation in kernel estimates – a square root law. Annals of Statistics 10. — 1982. — С. 1217–1223.

⁶⁷ Breiman, L., W. Meisel, E. Purcell Variable kernel estimates of multivariate densities. Technometrics 19. — 1977. — С. 135–144.

⁶⁸ Scott, D.W. (2012). Multivariate Density Estimation and Visualization.

3.1.5. Используемый подход

В данной работе используется метод ядерного сглаживания с классическим гауссовым ядром (7). В качестве baseline оценки оптимальной ширины окна используется эмпирическое правило Сильвермана для гауссова ядра (6). Для более точной оценки используется метод LOOCV (Leave-One-Out Cross-Validation), описанный, например, в статье Анатольева С.⁶⁹. В данном подходе критерием минимизации является функция кросс-валидации, в нашем случае основанная на среднеквадратичной ошибке:

$$LOOCV(h) = \frac{1}{n} \sum_{i=1}^n \left(y_i - \hat{g}^{-i}(x_i) \right)^2, \quad (13)$$

где $\hat{g}^{-i}(x_i)$ – это оценка Надарайа-Уотсона в точке x_i , использующая все наблюдения кроме i -го:

$$\hat{g}^{-i}(x_i) = \frac{\frac{1}{n} \sum_{j=1, j \neq i}^n y_j K_{h_n}(x_i - x_j)}{\frac{1}{n} \sum_{j=1, j \neq i}^n K_{h_n}(x_i - x_j)}, \quad (14)$$

Таким образом, оптимальная ширина в данном методе находится из задачи минимизации $LOOCV(h)$.

У предложенного выше метода есть серьёзный недостаток. LOOCV оптимален асимптотически, но при малых n его оценка MSE имеет большую дисперсию⁷⁰, чем у k -fold CV с $k < n$. Так как используются все данные для обучения (все точки кроме одной), то метод слишком подстраивается к данным, что приводит к недосглаживанию и увеличивает дисперсию предсказаний на новых данных.

Поэтому в качестве третьего метода для сравнения используется k -fold кросс-валидация⁷¹. Суть метода заключается в том, что данные разбиваются поровну на k частей, потом итеративно модель оценивается на всех частях, кроме одной, на которой замеряется критерий – в нашем случае MSE. Итоговой функцией кросс-валидации для минимизации является суммарное MSE по всем фолдам. Для маленьких датасетов оптимальное⁷² k по дисперсии ошибки выбора $h - k = 5$ или 10. В силу небольшого размера синтетического

⁶⁹ Anatolyev, Stanislav. (2009). Nonparametric regression (in Russian). Quantile. 37-52.

⁷⁰ Bengio Y., Grandvalet Y. No unbiased estimator of the variance of k -fold cross-validation //Journal of machine learning research. – 2004. – Т. 5. – №. Sep. – С. 1089-1105.

⁷¹ Analyzing Microarray Gene Expression Data. Wiley Series in Probability and Statistics. Wiley. 2004. doi:10.1002/047172842X. ISBN 978-0-471-22616-1.

⁷² Arlot, S. and Celisse, A. (2010) A Survey of Cross-Validation Procedures for Model Selection. Statistics Surveys, 4, 40-79. <https://doi.org/10.1214/09-SS054>

датасета ($n = 30$) в данной работе k выбирается равным 5, так как при выборе $k = 10$, на этап тестирования придётся всего 3 наблюдения. Таким образом, проблемой 5-fold CV в данном случае будет зашумленность тестирования, так как точек будет всего 6. Для избежания вычислительных проблем, связанных с переобучением выбор h для алгоритмов кросс-валидации, был ограничен диапазоном ($\exp(\ln h_{silverman} - 5), \exp(\ln h_{silverman} + 5)$).

Оба метода кросс валидации сталкиваются с ограничениями на исследуемом датасете и затруднительно заранее определить какой из них окажется лучше, поэтому в данном исследовании применяются оба варианта.

3.2. Информационный подход

3.2.1. Обзор метода

Данный подход является комбинацией метода энтропийно-робастного оценивания с «мягкой» рандомизацией и сравнения моделей с помощью информационного критерия BIC.

3.2.1.1. Изначальный подход

Используемый метод энтропийно-робастного оценивания, основан на изначальном подходе с «жесткой» рандомизацией, который впервые был предложен в работе А. Golan⁷³ и продолжал применяться и развиваться в том числе и в отечественных исследованиях^{74 75 76}. Далее представлена краткая формулировка метода в рамках нашей задачи. Пусть оцениваемая зависимость $g(x)$ представляет собой модель с параметрами $a \in R^r$, где r – количество параметров, т.е.

$$y = g(x, a) + \varepsilon, a \in R^r \quad (15)$$

Параметры и ошибки предполагаются непрерывными случайными величинами, которые определены на некоторых интервалах $a \in A = [a^-, a^+]$ и $\varepsilon \in U = [\varepsilon^-, \varepsilon^+]$. Целью метода является восстановление по данным оптимальных функций плотности

⁷³ Amos Golan, George G. Judge, Douglas Miller. Maximum Entropy Econometrics: Robust Estimation with Limited

Data. – John Wiley and Sons Ltd. Chichester, U.K., 1996.

⁷⁴ Yu. S. Popkov, Yu. A. Dubnov. Entropy-robust randomized forecasting under small sets of retrospective data // Automation and Remote Control. 2016, Volume 77, Issue 5, pp 839-854.

⁷⁵ Popkov, Y.S.; Dubnov, Y.A.; Popkov, A.Y. New Method of Randomized Forecasting Using Entropy-Robust Estimation: Application to the World Population Prediction. // Mathematics, 2016, Vol. 4, Iss.1, p.1-16.

⁷⁶ Дубнов Ю. А., Булычев А. В. Приближенное оценивание с помощью ускоренного метода наибольшей энтропии. Часть 1. Постановка задачи и реализация для задачи регрессии // Информационные технологии и вычислительные системы. – 2022. – №. 4. – С. 69-80.

распределения (ФПР) случайных величин $Q(\varepsilon)$ и $P(a)$. Это достигается путём максимизации функционала информационной энтропии:

$$H(P(a), Q(\varepsilon)) = - \int_A P(a) \ln P(a) da - \int_U Q(\varepsilon) \ln Q(\varepsilon) d\varepsilon \rightarrow \max_{P, Q} \quad (16)$$

при выполнении условий нормировки на искомые ФПР:

$$\int_A P(a) da = 1, \int_U Q(\varepsilon) d\varepsilon = 1; \quad (17)$$

и ограничений балансировки на выход модели:

$$E(\hat{y}_i) = E(g(x_i, a) + \varepsilon_i) = \int_A P(a) g(x_i, a) da + \int_U Q(\varepsilon) \varepsilon_i d\varepsilon = y_i, i = 1, \dots, n. \quad (18)$$

Как показано в работе Дубнова Ю. А. и Булычева А. В.⁷⁷ данная задача является вариационной задачей Лагранжа и имеет аналитическое решение, параметризованное множителями Лагранжа:

$$P^*(a, \lambda) = \frac{\exp(-\sum_{i=1}^n \lambda_i g(x_i, a))}{\int_A \exp(-\sum_{i=1}^n \lambda_i g(x_i, a)) da}, \quad (19)$$

$$Q^*(\varepsilon, \lambda) = \frac{\exp(-\sum_{i=1}^n \lambda_i \varepsilon_i)}{\int_U \exp(-\sum_{i=1}^n \lambda_i \varepsilon_i) d\varepsilon}, \quad (20)$$

где множители Лагранжа вычисляются из системы уравнений, полученной подстановкой полученных плотностей (19) и (20) в балансовые ограничения (18). Отсюда следует основное ограничение метода – необходимость решать систему уравнений размерности n . При большом количестве точек это становится очень затратной с вычислительной точки зрения задачей в связи с проклятием размерности. Кроме того, на практике также возникают проблемы, связанные с наличием множества локальных оптимумов в многомерном пространстве. Именно поэтому в рамках данного исследования используется подход с «мягкой» рандомизацией, который за счёт регуляризации позволяет найти приближенную функцию распределения с меньшим количеством вычислительных затрат.

3.2.1.2. Модифицированный метод

⁷⁷ Там же

Метод в первые был предложен⁷⁸ и исследован⁷⁹ в работах Ю. Дубнова и А. Булычёва. В данной работе исследуются возможности и качество оценки предложенного метода в контексте оценки регрессии.

3.2.1.2.1. Теоретический вывод метода

Для начала кратко изложим суть приближённого метода. Постановка задачи в виде (15) на некоторых интервалах $a \in A = [a^-, a^+]$ и $\varepsilon \in U = [\varepsilon^-, \varepsilon^+]$ сохраняется, однако вместо точной оптимизации используется приближённое балансирование предсказаний $\hat{y} = g(x, a)$ и истинных данных y через гильдеровы нормы⁸⁰:

$$N_a(a) = \|g(x, a) - y\|_H, \quad (21)$$

$$N_\varepsilon(\varepsilon) = \|\varepsilon\|_H, \quad (22)$$

где $N_a(a)$ – расстояние между моделью и данными, $N_\varepsilon(\varepsilon)$ – норма вектора шума ε .

Далее вводится математическое ожидание норм как «эмпирический риск»⁸¹, который позволяет учесть статистику распределения параметров a и ошибок ε :

$$\overline{N}_a(P(a)) = E(N_a(a)) = \int_A P(a) N_a(a) da, \quad (23)$$

$$\overline{N}_\varepsilon(Q(\varepsilon)) = E(N_\varepsilon(\varepsilon)) = \int_U Q(\varepsilon) N_\varepsilon(\varepsilon) d\varepsilon. \quad (24)$$

Для оптимизации строится синтетический функционал $J(P(a), Q(\varepsilon))$, объединяющий энтропийную меру неопределённости (16), «эмпирический риск» (23) и среднюю норму ошибок (24):

$$J(P(a), Q(\varepsilon)) = H(P(a), Q(\varepsilon)) - \overline{N}_a(P(a)) - \overline{N}_\varepsilon(Q(\varepsilon)). \quad (25)$$

Задача сводится к максимизации (25) при условиях нормировки (17). Таким образом, для решения больше не требуется выполнения балансовых ограничений, а следовательно, и решения системы из n уравнений. Для учёта ограничений вводится функционал Лагранжа:

⁷⁸ Там же.

⁷⁹ Дубнов Ю. А., Булычев А. В. Приближённое оценивание с помощью ускоренного метода наибольшей энтропии. Часть 2. Исследование свойств оценок // Информационные технологии и вычислительные системы. – 2023. – №. 1. – С. 71-81.

⁸⁰ Воеводин В.В., Кузнецов Ю.А. Матрицы и вычисления. М., Наука, 1984.

⁸¹ Цыпкин Я.З. Основы теории обучающихся систем. М., Наука, 1970.

$$L(P(a), Q(\varepsilon)) = J(P(a), Q(\varepsilon)) + \nu \left(1 - \int_A P(a) da\right) + \mu \left(1 - \int_U Q(\varepsilon) d\varepsilon\right), \quad (26)$$

где ν и μ – штрафные параметры. Условия оптимальности выводятся через производные Гато⁸². Так как $P(a) \in \mathbb{C}_1$, $Q(\varepsilon) \in \mathbb{C}_1$, то их вариацию можно представить в виде:

$$P(a) = P^*(a) + \alpha p(a), \quad (27)$$

$$Q(\varepsilon) = Q^*(\varepsilon) + \beta q(\varepsilon), \quad (28)$$

где $\alpha, \beta \in \mathbb{R}$, $p(a), q(\varepsilon) \in \mathbb{C}_1$. Тогда производные Гато и условия оптимальности для параметров имеют следующий вид:

$$\begin{aligned} \left. \frac{dL}{d\alpha} \right|_{\alpha=0} &= \frac{d}{d\alpha} \left[- \int_A (P^*(a) + \alpha p(a)) \ln(P^*(a) + \alpha p(a)) da - \int_A (P^*(a) + \alpha p(a)) N_a(a) da \right] \Big|_{\alpha=0} \\ &= \left[- \int_A \left(p(a) \ln(P^*(a) + \alpha p(a)) + p(a) + p(a) N_a(a) \right) da \right] \Big|_{\alpha=0} \\ &= \int_A p(a) (\ln P^*(a) + 1 + N_a(a)) da = 0, \end{aligned} \quad (29)$$

Для шума условия имеют аналогичный вид:

$$\begin{aligned} \left. \frac{dL}{d\beta} \right|_{\beta=0} &= \frac{d}{d\beta} \left[- \int_U (Q^*(\varepsilon) + \beta q(\varepsilon)) \ln(Q^*(\varepsilon) + \beta q(\varepsilon)) d\varepsilon - \int_U (Q^*(\varepsilon) + \beta q(\varepsilon)) N_\varepsilon(\varepsilon) d\varepsilon \right] \Big|_{\beta=0} \\ &= \left[- \int_U \left(q(\varepsilon) \ln(Q^*(\varepsilon) + \beta q(\varepsilon)) + q(\varepsilon) + q(\varepsilon) N_\varepsilon(\varepsilon) \right) d\varepsilon \right] \Big|_{\beta=0} \\ &= \int_U q(\varepsilon) (\ln Q^*(\varepsilon) + 1 + N_\varepsilon(\varepsilon)) d\varepsilon = 0, \end{aligned} \quad (30)$$

Обращение в ноль подынтегральных выражений является необходимым и достаточным условием, чтобы уравнения (29) и (30) выполнялись при любых функциях $p(a)$ и $q(\varepsilon)$. Таким образом, решение задачи в общем виде имеет следующий вид:

$$P^*(a) = \frac{\exp(-N_a(a))}{\int_A \exp(-N_a(a)) da}, \quad (31)$$

⁸² Kaashoek M.A., Seatzu S., van der Mee C. Recent Advances in Operator Theory and its Application. 2006, Springer, p.478.

$$Q^*(\varepsilon) = \frac{\exp(-N_\varepsilon(\varepsilon))}{\int_U \exp(-N_\varepsilon(\varepsilon)) d\varepsilon}, \quad (32)$$

Таким образом, оптимальные функции плотности вероятности имеют экспоненциальную форму, т.е. вероятность параметров a уменьшается экспоненциально с ростом ошибки $N_a(a)$ и аналогично для ошибок ε . Однако точная структура распределения определяется самими функциями эмпирического риска $N_a(a)$ и нормы ошибок $N_\varepsilon(\varepsilon)$. Авторы работы также пишут «поскольку величина эмпирического риска $N_a(a)$ зависит не только от параметров модели, но и от имеющихся измерений, то функцию $P^*(a)$ можно трактовать как аналог функции правдоподобия при имеющейся выборке наблюдений. Следовательно, в задачах оценивания при отсутствии информации о виде распределения ошибок и настоящей функции правдоподобия технология «мягкого» энтропийного оценивания позволяет восстановить ее альтернативу.»⁸³. Таким образом, по полученной плотности $P^*(a)$ можно получить точечную оценку параметров путём нахождения точки максимума плотности и это будет аналог оценки максимума правдоподобия в контексте энтропийно-оптимальных функций. Эта задача эквивалентна задаче минимизации «эмпирического риска» (21):

$$\max_a P^*(a) \sim \max_a \exp(-N_a(a)) \sim \min_a N_a(a)$$

Также существует второй способ оценки путём нахождения математического ожидания параметров по плотности $P^*(a)$, однако в данной работе применяется именно первый метод.

3.2.1.2.2. Применение для оценки регрессии

В рамках данной работы для оценки регрессии используются полиномиальные регрессии (5) со степенями от 1 до 6, которые в свою очередь оцениваются предложенным энтропийным методом.

В качестве нормы в данном исследовании берётся комбинация L_1 и L_2 норм:

$$N_a(a) = c_1 \|\hat{y} - y\|_1 + c_2 \|\hat{y} - y\|_2 = c_1 \sum_{i=1}^n |\hat{y}_i - y_i| + c_2 \sum_{i=1}^n (\hat{y}_i - y_i)^2, \quad (34)$$

⁸³ Дубнов Ю. А., Булычев А. В. Приближенное оценивание с помощью ускоренного метода наибольшей энтропии. Часть 1. Постановка задачи и реализация для задачи регрессии // Информационные технологии и вычислительные системы. – 2022. – №. 4. – С. 69-80.

где L_1 компонента отбрасывает нерелевантные параметры, зануляя их, а L_2 компонента контролирует масштаб коэффициентов, стабилизируя оценки. Для выбора оптимальной степени полинома, а также c_1 и c_2 можно использовать как эмпирические методы, так и теоретические критерии. В данной работе для этой задачи применяется метод .632+ бутстреп⁸⁴ (см. главу 3.2.4). Общее решение (31) представляется в следующем виде:

$$P^*(a) = \frac{\exp(-c_1 \sum_{i=1}^n |\hat{y}_i - y_i| - c_2 \sum_{i=1}^n (\hat{y}_i - y_i)^2)}{\int_A \exp(-c_1 \sum_{i=1}^n |\hat{y}_i - y_i| - c_2 \sum_{i=1}^n (\hat{y}_i - y_i)^2) da}. \quad (35)$$

В заключение стоит отметить, что в случае $c_1 = 0$, т.е. использовании в расчётах только L_2 регуляризации оценка как точка максимума энтропийно-оптимальной функции плотности распределения $P^*(a)$ совпадает с оценкой по МНК. Однако в остальных случаях экспоненциальные распределения имеют более сложную форму и приводят к другим оценкам.

3.2.2. Преимущества метода

Основное теоретическое преимущество энтропийного метода заключается в его фокусе на первичной информации, а именно функции плотности распределения параметров. Любая интерпретация функции распределения — это сжатие информации из выборки с потерями. Энтропийное оценивание позволяет отыскать именно функцию распределения для параметров. В дальнейшем можно проводить операции с функцией распределения, но именно она представляет из себя первичную информацию: вычисление энтропийных статистик, в частности, моментов информационного содержания, которые проявляют устойчивость для отдельных видов распределений. Например, для нормального дисперсия информационного разброса равна 0.5.

Другим серьёзным преимуществом предложенного метода является отсутствие каких-либо ограничений на ошибки и параметры, кроме отрезка определения. Более того, при выборе оценки как точки максимума энтропийно-оптимальной функции плотности распределения $P^*(a)$ в общем случае не требуется даже отрезок определения, так как его можно выбрать произвольным. Энтропийный подход позволяет получить обоснованные оценки плотности параметров и ошибок в сложных случаях, когда предпосылки классических подходов нарушаются. В частности, можно использовать плотность $P^*(a)$ в качестве аналога функции правдоподобия, когда не представляется возможным построить её обычными методами. Наконец, сами оценки параметров можно выбирать как максимум

⁸⁴ Efron B., Tibshirani R. Improvements on cross-validation: the 632+ bootstrap method //Journal of the American Statistical Association. – 1997. – Т. 92. – №. 438. – С. 548-560.

плотности, математическое ожидание, медиану или другими методами, основанными на плотности распределения параметров.

Преимуществом конкретно метода «мягкой» рандомизации по сравнению с базовой версией является отсутствие необходимости вычислять множители Лагранжа в системе балансовых уравнений размерности n . Это позволяет кратно уменьшить вычислительные затраты метода, так как задача сводится к оптимизации с размерностью равной количеству параметров. Благодаря этому метод освобождается от проклятья размерности и независимо от количества точек считается достаточно быстро при выборе классических норм⁸⁵. Более того, при выборе уже упомянутого выше подхода оценки максимума плотности $P^*(a)$ пропадает необходимость считать нормировочный интеграл, и задача сводится к минимизации выбранной нормы по параметрам, что значительно ускоряет расчёты, особенно на больших датасетах, но эффект сильно заметен даже на исследуемых датасетах из 30 наблюдений.

Эффективность метода «мягкой» рандомизации в контексте оценки линейной регрессии была экспериментально исследована в работе⁸⁶ Дубнова Ю. А. и Булычева А. В.. Результаты указывают на то, что метод является более эффективным по сравнению с аналогами при ассиметричном распределении ошибок модели или если они распределены не нормально, а также при оценке на малых выборках.

3.2.3. Ограничения метода

Несмотря на значительное ускорение вычислений энтропийного метода с «мягкой» рандомизацией, существуют системные ограничения, связанные с использованием приближённого подхода.

Во-первых, происходит потеря информации из-за отклонения от принципа максимума энтропии и асимптотического характера гарантий. В методе с «жёсткой» рандомизацией при выполнении балансовых ограничений полученные в результате максимизации энтропии оценки теоретически являются наилучшими в условиях

⁸⁵ Дубнов Ю. А., Булычев А. В. Приближенное оценивание с помощью ускоренного метода наибольшей энтропии. Часть 2. Исследование свойств оценок // Информационные технологии и вычислительные системы. – 2023. – №. 1. – С. 71-81.

⁸⁶ Там же.

неопределённости^{87 88 89}. Предложенный приближённый метод, исходя из вывода, асимптотически сохраняет это свойство, однако за счёт потери части информации.

Во-вторых, выбор нормы для «эмпирического риска» определяет итоговые оценки, тем самым косвенно сужая возможные решения. Таким образом, форма «эмпирического риска» в некотором роде параметризует оценки, превращая метод в параметризованный компромисс между данными и субъективным выбором метрики отклонения.

3.2.4. Используемый подход

В рамках данного исследования используется описанный выше энтропийный подход с «мягкой» рандомизацией и оценка как точка максимума энтропийно-оптимальной функции плотности распределения $P^*(a)$. Максимум ищется с помощью метода `minimize` библиотеки `Python scipy`⁹⁰ методом Пауэлла⁹¹, так как он работает с негладкими функциями. В качестве «эмпирического риска» используется комбинация норм L_1 и L_2 , как описано в главе 3.2.1.2.2. Коэффициенты c_1 и c_2 подбираются по сетке соотношений: 1:0, 0:1, 1:1, 3:4, 4:3, 1:2, 2:1, 1:4, 4:1.

Оптимальная комбинация степени и соотношения $c_1:c_2$, как описывалось выше, подбирается с помощью метода `.632+` бутстрап⁹². Кратко опишем алгоритм подбора для каждой комбинации.

Для каждой модели генерируется B бутстреп-выборок $\mathcal{L}^b$ размера n с возвращением и для каждой выборки определяются выброшенные точки $\mathcal{C}^b$, которые не попали в $\mathcal{L}^b$. Количество выборок B на практике рекомендуется брать от 200 до 500. В силу большого количества датасетов для тестирования в данной работе B берётся равным 200.

⁸⁷ Jaynes E.T. Information Theory and Statistical Mechanics // Physics Review Notes. 1957. V. 106. P. 620–630.

⁸⁸ R.D. Levin, M. Tribus. The maximum entropy formalism. MIT Press, 1979.

⁸⁹ Jaynes E.T. Probability Theory. The logic and science. Cambridge Univ. Press, 2003.

⁹⁰ Virtanen P. SciPy 1.0: fundamental algorithms for scientific computing in Python / P. Virtanen, R. Gommers, T. E. Oliphant [et al.] // Nature Methods. — 2020. — Vol. 17, № 3. — P. 261–272. — DOI: 10.1038/s41592-019-0686-2.

⁹¹ M. J. D. Powell. An efficient method for finding the minimum of a function of several variables without calculating derivatives (англ.) // The Computer Journal. — 1964. — 1 January (vol. 7). — P. 155–162.

⁹² Efron B., Tibshirani R. Improvements on cross-validation: the 632+ bootstrap method // Journal of the American Statistical Association. — 1997. — T. 92. — №. 438. — С. 548–560.

Для каждой бутстреп-итерации b обучается модель на $\mathcal{L}^b$, вычисляется ошибка на обучении err_{train}^b и выброшенных точках err_{boot}^b . Считается пессимистичная ошибка модели, которая делает предсказания независимо от данных:

$$\gamma^b = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n L(y_i^b, \hat{y}_j^b), \quad (36)$$

где L – квадрат ошибки. γ^b по сути является ошибкой при случайном сопоставлении.

Ошибки усредняются по выборкам:

$$err_{train} = \frac{1}{B} \sum_{i=1}^B err_{train}^b, err_{boot} = \frac{1}{B} \sum_{i=1}^B err_{boot}^b, \gamma = \frac{1}{B} \sum_{i=1}^B \gamma^b.$$

Вычисляется относительное переобучение:

$$R = \frac{err_{boot} - err_{train}}{\gamma - err_{train}}, \quad (37)$$

где числитель – это абсолютное переобучение, а знаменатель – это максимально возможное переобучение. На основе относительно переобучения вычисляется адаптивный вес

$$w = \frac{0.632}{1 - 0.368 \cdot R} \quad (38)$$

и итоговая ошибка

$$Err_{.632+} = (1 - w) \cdot err_{train} + w \cdot err_{boot}, \quad (39)$$

При сильном переобучении ($R \rightarrow 1$) вес ошибки на обучающих точках уменьшается, что предотвращает выбор излишне сложных моделей.

Таким образом, алгоритм применяется ко всем комбинациям степени и соотношения $c_1 : c_2$, после чего выбирается вариант с наименьшей ошибкой $Err_{.632+}$.

Данный метод был выбран, так как модели оцениваются на очень маленьких выборках ($n = 30$). В этом случае методы кросс-валидации имеют большую дисперсию, чем предложенный метод, так как валидация происходит на очень маленьком количестве точек, а бутстреп использует перекрывающиеся выборки, что уменьшает дисперсию по сравнению с кросс-валидацией. Кроме того, полиномы оцениваются очень быстро энтропийным методом, поэтому в данном случае применение бутстрепа является

оправданным. В работе Эфрона⁹³ также доказывается асимптотическая несмещённость метода.

4. Практическая часть

В данной главе подробно описаны реализации предложенных в главе 3 методов, а также представлены результаты генерации и оценивания.

4.1. Генерация датасетов

4.1.1. Полиномиальные регрессии

По описанному в главе 2.2.3.1. процессу было сгенерировано 5400 датасетов (6 степеней, 3 диапазона относительного уровня ошибок, по 300 точек в каждом). Для контроля случайности были использованы seed от 1 до 5400 соответственно, что гарантирует реплицируемость генерации. На рис. 3-5 приведены примеры этих датасетов при разных уровнях шума и степени.

⁹³ Там же.




Рис. 3. Примеры датасетов при низком относительном уровне шума.




Рис. 4. Примеры датасетов при умеренном относительном уровне шума.




Рис. 5. Примеры датасетов при высоком относительном уровне шума.

При низком уровне шума линия регрессии визуально хорошо различима, шум почти не искажает данные, что позволяет тестировать способность методов различать локальные особенности. Эти датасеты моделируют высокачественные измерения в лабораторных экспериментах.

При высоком уровне шума, наоборот, линию регрессии становится сложно точно определить. Этот вариант моделируют сложные условия, такие как сенсорные данные в

реальном времени. На данном типе датасетов проверяется робастность методов к случайным возмущениям.

Средний уровень шума представляет собой баланс этих краевых случаев и является стандартом в исследовании методов оценки регрессии⁹⁴.

В итоговых датасетах достигается достаточно высокое разнообразие параметров генерации и точность относительного уровня шума. На рис. 6 представлена диаграмма рассеяния, которая демонстрирует равномерное покрытие как фактора масштаба, так и фактора смещения для всех 540 датасетов. Цветовая кодировка по степени указывает на отсутствие систематического смещения в этой части генерации. Кроме того, боксплоты отклонений фактического относительного уровня шума от целевых значений на рис. 7 указывает на корректность подгонки коэффициентов и машинную точность генерации. Ожидаемо, отклонение больше при генерации с более высоким шумом. При этом максимальное отклонение составляет порядка 10^{-15} . Таким образом, влияние шума на оценку методов является полностью контролируемым.

⁹⁴ Härdle W. Applied Nonparametric Regression / W. Härdle. — Cambridge : Cambridge University Press, 1990. — 334 p. — ISBN 0-521-36985-8




Рис. 6. Распределение параметров генерации полиномов.




Рис. 7. Точность достижения целевого уровня шума.

На рис. 8-13 ниже представлены распределения коэффициентов разных степеней полиномов при умеренном уровне шума. Отсутствие вырожденных распределений и

разнообразие значений коэффициентов указывает на корректность генерации, исключая влияние артефактов на оценку качества методов.




Рис. 8. Распределение коэффициентов полинома 1-й степени (300 датасетов, умеренный шум).




Рис. 9. Распределение коэффициентов полинома 2-й степени (300 датасетов, умеренный шум).




Рис. 10. Распределение коэффициентов полинома 3-й степени (300 датасетов, умеренный шум).




Рис. 11. Распределение коэффициентов полинома 4-й степени (300 датасетов, умеренный шум).




Рис. 12. Распределение коэффициентов полинома 5-й степени (300 датасетов, умеренный шум).




Рис. 13. Распределение коэффициентов полинома 6-й степени (300 датасетов, умеренный шум).

Таким образом, предложенный подход корректно генерирует синтетические данные для оценки полиномов, позволяя качественно протестировать и оценить предложенные методы и ответить на ключевые исследовательские вопросы дипломной работы.

4.1.2. Двумерная смесь нормальных распределений

По описанному в главе 2.2.3.2. методу было сгенерировано 300 датасетов детерминированной смеси и 300 датасетов стохастической смеси. Примеры генераций представлены на рис. 14. Детерминированный подход позволяет точно контролировать соотношение точек из различных компонент, что позволяет изолировать влияние случайных отклонений на оценку качества методов и сосредоточиться на базовой погрешности. Стохастический подход более реалистично моделирует распределение, что добавляет шум, связанный с разным количеством точек, но за счёт этого создаёт условия для проверки предложенных методов на робастность к случайным отклонениям в структуре данных.




Рис. 14. Примеры генераций смеси распределений.

Как указано в главе 2.3.1 для оценки качества модели по метрикам IMSE и IMAE был выбран отрезок от -1.5 до 6.5, так как он содержит 95% вероятностной массы распределения. Эмпирический анализ сгенерированных датасетов подтверждает теоретическую корректность такого выбора (см. рис. 15): в детерминированной смеси в диапазон попадает 95.2% точек, а в стохастической 95.0%. Кроме того, формы распределения компонент по x практически совпадают. Статистические характеристики также практически не отличаются (см. рис. 16). Таким образом, несмотря на различия в

подходах, конечная модель синтетических данных остаётся в достаточной степени одинаковой.




Рис. 15. Анализ распределения точек смеси по оси x в генерациях.




Рис. 16. Полная статистическая характеристика сгенерированных смесей.

Однако важно отметить, что несмотря на одинаковость в среднем, следующую из теории, в отдельных отклонениях различия, за счёт которых тестируется робастность, наблюдаются. На рис. 17. видно количество точек из второго компонента отличаются от датасета к датасету и приблизительно следует биномиальному распределению $Binom(30, 2)$.




Рис. 17. Распределение количества точек из компонента 2 (стохастическая генерация, 300 датасетов).

Таким образом, анализ даёт представление о статистических свойствах сгенерированных данных и демонстрирует, что предложенная генерация корректна в рамках данного исследования.

4.2. Оценка моделей на синтетических данных

4.2.1. Полиномиальные данные

4.2.1.1. Оценка ядерной регрессии

По результатам оценки полиномиальных датасетов были получены оценки метрик, представленные в Приложении 3.

4.2.1.1.1. Очистка от выбросов и оценка их влияния

Для избавления от влияния выбросов в метриках результаты были очищены с помощью метода полуторного межквартильного размаха. Итоговые оценки представлены в Приложении 4.

По результатам очистки в среднем по всем конфигурациям было отброшено 10% датасетов (см. рис. 18). Правило Сильвермана показало себя немного более стабильным,

чем методы кросс валидации с точки зрения выбросов. Различие по уровням шума так же небольшое (см. рис. 19). Важно отметить, что методы кросс-валидации имеют на 30-50% больше выбросов чем правило Сильвермана, что подтверждает их вычислительную нестабильность. Однако для 5-fold CV доля выбросов падает с повышением уровня шума, что может указывать на меньшие проблемы с переобучением, как и предполагалось в главе 3.1.5.




Рис. 18. Сравнение методов по доле удалённых выбросов (усреднено по всем конфигурациям).




Рис. 19. Сравнение методов по доле удалённых выбросов (без усреднения).

Очистка данных привела к значительному улучшению метрик, особенно IMSE и MaxErr (см. рис. 20). Наибольшее относительное улучшение IMSE наблюдается для 4 степени при низком шуме (уменьшение более чем на 90%), где выбросы были наиболее экстремальными. IMAE менее чувствительна к выбросам, поэтому её улучшение было меньше остальных.




Рис. 20. Влияние IQR-очистки на IMSE по степеням полинома.

Кроме того, очистка от выбросов аналогично значительно снизила стандартную ошибку для всех методов (см. рис. 21). Методы кросс-валидации выиграли больше всего от очистки – их SEM уменьшился в 10-20 раз, что позволило им сравниться по стабильности с правилом Сильвермана. Это объясняется тем, что большая часть ошибок и экстремальных значений кросс-валидации связана с переобучением. Таким образом, результаты указывают на то, что правило Сильвермана является более робастным.




Рис. 21. Снижение стандартной ошибки (SEM) после IQR-очистки.

4.2.1.1.2. Анализ очищенных результатов

При увеличении степени среднее значение выбранной ширины окна для методов кросс-валидации падает для всех уровней шума (см. рис. 22.). Так для первой степени средняя ширина окна колеблется около 10, а для полинома 6 степени выбирается гораздо более локальное значение $h \approx 1$. Это свидетельствует об адаптации методов к сложности данных – для линейного тренда оптимальным является глобальное усреднение, фактически эквивалентное переходу к линейной регрессии, но с увеличением сложности зависимости окно уменьшается, переходя к локальному сглаживанию. Однако важно отметить высокую вариативность выбранных значений ширины окна предложенных методов кросс-валидации ($std \approx 3 - 9$). Таким образом, на малых выборках ($n = 30$) выбор ширины окна сильно определяется конкретной реализацией шума, что приводит к большой дисперсии гиперпараметра h . Эмпирическое правило Сильвермана зависит только от x , поэтому не адаптируется к данным и всегда стабильно в выборе h . Во многом эти наблюдения объясняют результаты оценки метрик.




Рис. 22. Адаптивность подбора ширины окна.

Анализ метрик IMSE, IMAE и MaxErr (см. рис. 23-25), показал, что эффективность подходов зависит от степени и уровня шума. Для линейной регрессии методы кросс-валидации показывают статистически значимо лучшие результаты, чем правило Сильвермана, в подавляющем большинстве случаев. С ростом сложности модели эффективность начинает зависеть от уровня шума. При низком и умеренном уровне шума все методы дают статистически неразличимы результаты, однако для полиномов высоких степеней оба метода кросс-валидации показывают статистически значимо лучшие результаты по всем метрикам. Фиксированное маленькое окно по правилу Сильвермана ($h \approx 0.15$) приводит к переобучению – модель следует за каждой точкой, включая выбросы. Методы кросс-валидации адаптируются и находят баланс между сглаживанием шума и сохранением формы полинома.




Рис. 23. Сравнение ядерных методов: IMSE в зависимости от степени полинома.




Рис. 24. Сравнение ядерных методов: IMAE в зависимости от степени полинома.




Рис. 25. Сравнение ядерных методов: MaxErr в зависимости от степени полинома.

На датасетах с высоким уровнем шума все методы дают статистически неразличимые результаты в большинстве случаев. Более того, средние оценки по правилу Сильвермана получаются лучше. Таким образом, можно сделать вывод, что с повышением уровня шума эффективность кросс-валидационных подходов теряется. Вероятно, это происходит потому, что при высоком уровне шума 30 точек недостаточно для его преодоления и он оказывает слишком большое влияние на подбор ширины окна.

Переходя к сравнению двух подходов кросс-валидации – LOOCV и 5-fold CV – можно заметить, что они показывают очень близкие результаты по точности и практически не различаются по устойчивости после учёта выбросов (см. рис. 26).




Рис. 26. Стабильность оценок ядерных методов по IMSE.

Наконец, стоит отметить интересную закономерность снижения средних оценок ошибок при увеличении шума. Это наблюдение может иметь несколько интерпретаций. С одной стороны, это может быть артефактом генерации данных. С другой стороны, возможно сильный шум «спасает» методы от переобучения на маленьком количестве точек, размывая данные, и тем самым улучшая качество кросс-валидации.

4.2.1.2. Оценка энтропийным методом

По результатам оценки полиномиальных датасетов были получены оценки метрик, представленные в Приложении 5.

4.2.1.2.1. Анализ подбора параметров

Анализ статистики по подобранным параметрам показал адаптивность предложенного метода, однако также выявил некоторые особенности. В первую очередь хочется отметить относительный баланс параметров регуляризации в норме c_1 и c_2 . Для всех степеней наблюдается достаточно большой разброс в выборе итогового соотношения (см. рис. 27), однако среднее значение недалеко от равных весов. Кроме того, $\bar{c}_2 \in [0.53, 0.59]$, то есть в среднем L2 регуляризация немного преобладает над L1, что указывает на предпочтение «мягкой» регуляризации. На графике также видно, что с ростом истинной степени c_2 немного увеличивается, то есть метод адаптивно усиливает L2-штраф для контроля дисперсии при усложнении зависимости в данных.




Рис. 27. Вклад L2-регуляризации в зависимости от сложности задачи.

Распределение подобранных степеней (см. рис. 28) в свою очередь демонстрирует одну из ключевых особенностей выбранного подхода. Тепловая карта показывает, что присутствует выраженный байсовский скептицизм – комбинация .632+ бутстрапа и максимизации энтропии приводит к тому, что модель предпочитает более простые модели. Это спасает модель от переобучения на малых истинных степенях, однако приводит к систематическому занижению степени на высоких (≥ 3) степенях (см. рис. 29). Кроме того, более высокий шум работает как дополнительная неявная регуляризация, что приводит к дополнительному занижению степени в среднем.




Рис. 28. Распределение выбранных степеней (в процентах по строкам).




Рис. 29. Систематическое смещение подбора степени полинома.

4.2.1.2.2. Очистка от выбросов и оценка их влияния

Была также проведена очистка от выбросов методов по методу 1,5 IQR. Результаты расчёта метрик после очистки представлены в Приложении 6. Доля отброшенных датасетов в среднем составила около 9,5%, что немного ниже 10% для ядерных методов, однако различие незначительно и скорее указывает на особенности генерации данных. Рассматривая данные более детально (см. рис. 30), можно отметить, что шум слабо влияет на стабильность, в то время как с ростом степени в среднем она увеличивается.




Рис. 30. Сводная статистика по удалению выбросов: энтропийный метод.

Очистка от выбросов улучшила значения метрик (см. рис. 31) и их стандартных отклонений (см. рис. 32), однако не так радикально, как для ядерных методов. Среднее улучшение IMSE составило 33,2%, а его стандартного отклонения – 64,3%, что сравнимо по стабильности с эмпирическим правилом Сильвермана. Таким образом, результаты указывают на достаточную стабильность метода на малых данных, по сравнению с методами кросс-валидации.




Рис. 31. Влияние IQR-очистки на IMSE: энтропийный метод.




Рис. 32. Снижение стандартной ошибки (SEM) после IQR-очистки: энтропийный метод.

4.2.1.2.3. Анализ очищенных результатов

Полученные данные показывают (см. рис. 33), что средние значения метрик статистически значимо не различаются между уровнями шума в большинстве случаев, однако ошибки закономерно растут с увеличением сложности модели. Также можно отметить интересную закономерность, на высоком уровне шума ошибки в среднем меньше. Это указывает на склонность метода к частичному переобучению при низком шуме – модель слишком сильно «верит» в данные и подстраивается под них. Для стандартного отклонения ошибок наблюдается аналогичная тенденция (см. рис. 32), однако с ростом шума разница между степенями уменьшается.




Рис. 33. Метрики качества энтропийного метода после очистки.

4.2.1.3. Сравнение методов

Общий анализ результатов оценивания после очистки от выбросов и сравнение методов по полученным метрикам указывает на систематически более высокую точность метода энтропийного оценивания на полиномиальных данных по сравнению со всеми методами регрессии. Энтропийный метод показал лучшие средние значения по сравнению с лучшим результатом ядерных методов (с учётом SEM) по всем метрикам на всех 18 конфигурациях (см. рис. 34-36). При помощи стандартного t-теста Уэлча при разных дисперсиях выборок была протестирована гипотеза об отсутствии различий между средним метрикам. Результаты приведены в виде тепловой карты p-value на рис. 37-39. Для значимости различий используются следующие обозначения: * - 10%, ** - 5%, *** - 1%, **** - 0.1%. Статистическая значимость рассчитывалась с учётом поправки Бонферрони, так как тестировалось сразу 3 метрики.




Рис. 34. Сравнение методов регрессии: IMSE в зависимости от степени полинома.




Рис. 35. Сравнение методов регрессии: IMAE в зависимости от степени полинома.




Рис. 36. Сравнение методов регрессии: максимальная ошибка в зависимости от степени полинома.




Рис. 37. Значимость различий: Энтропия vs Ядерная регрессия, IMSE.




Рис. 38. Значимость различий: Энтропия vs Ядерная регрессия, IMAE.




Рис. 39. Значимость различий: Энтропия vs Ядерная регрессия, MaxErr.

Наименьшее и статистически незначимое различие по всем метрикам наблюдается для первой степени и низкого уровня шума, где все методы справляются практически одинаково хорошо. С ростом шума различие увеличивается и при умеренном и высоком уровне шума различия становятся статистически значимыми для IMSE и IMAE. Однако начиная со второй степени различия резко увеличиваются и становятся статистически значимыми. При низком и умеренном уровнях шума по всем метрикам различия статистически значимы на уровне 0.1%. При высоком уровне шума наблюдается деградация методов и в некоторых конфигурациях различия становятся менее значимыми (3, 4 и 6 степень) или незначимыми (4 степень IMSE), однако общее преимущество энтропийного метода сохраняется. На рис. 40 представлены процентные улучшения по IMSE – наибольшее улучшение составило 47,8%.




Рис. 40. Преимущество энтропийного метода над ядерной регрессией (по IMSE, %).

Таким образом, можно сделать вывод о систематическом и статистически значимом превосходстве метода по метрикам IMSE, IMAE и MaxErr на полиномиальных данных. Основной причиной результата можно выделить нестабильность подходов ядерной регрессии на малых данных, особенно при низком уровне шума, где методы кросс-валидации склонны к сильному переобучению или нестабильному подбору ширины окна. Предложенный метод «мягкого» энтропийного оценивания является более стабильным за счёт адаптивного подбора параметров степени и регуляризации бутстрепом. Однако важно отметить, что разрыв не увеличивается с ростом сложности модели, так как энтропийный метод склонен перестраховываться и выбирать более простую модель, о чём упоминалось выше, что не позволяет ему нарастить преимущество.

4.2.2. Двумерная смесь нормальных распределений

4.2.2.1. Оценка ядерной регрессии

Результаты оценивания представлены в Приложении 7.

4.2.2.1.1. Очистка от выбросов и оценка их влияния

Аналогично предыдущим пунктам была проведена очистка от выбросов в метриках. Результаты представлены в Приложении 8. Как видно из рис. 41, выбросы составили 10-14% датасетов. Доли выбросов различаются по генерациям и методам. Больше всего выбросов наблюдается у правила Сильвермана. Методы кросс-валидации имеют практически одинаковые результаты, но в среднем LOOCV немного лучше.




Рис. 41. Процент выбросов, удалённых методом 1.5 IQR.

Очистка от выбросов также заметно уменьшила метрики и стандартные ошибки (см. рис. 42, 43), но масштаб улучшений значительно отличается. Правило Сильвермана больше всего выигрывает от очистки выбросов, например в детерминированной генерации метрика IMSE улучшилась в ~70 раз, что указывает на наличие катастрофических выбросов, которые метод неспособен обработать. Для методов 5-fold CV и LOOCV улучшение умеренное (в 6-8 раз), что указывает на большую робастность и адаптивность этих методов. Аналогичные тенденции наблюдаются для снижения SEM. Все значения SEM снизились в 10-20 раз после очистки. Таким образом, можно сделать вывод, что при оценке на смесях данные методы достаточно нестабильны и требуют аккуратной настройки для обработки экстремальных случаев.




Рис. 42. Снижение стандартной ошибки (SEM) после IQR-очистки. Источник: работа автора.




Рис. 43. Сравнение IMSE до и после очистки методом 1.5 IQR. Источник: работа автора.

Плохие результаты правила Сильвермана объясняются тем, что выбор ширины окна выводится в предположении, что данные имеют унимодальное гауссовское распределение, в то время как распределение смеси бимодально. Это приводит к неоптимальному выбору слишком маленького h и недосгалживанию. Из-за слишком маленького окна метод чаще «проваливается» в дыры между точками, что приводит к огромным выбросам ошибок.

Отдельно стоит отметить различия, связанные с генерацией. Кросс-валидация показывает ожидаемые результаты — на стохастической генерации методы менее стабильны за счёт добавления вариации в данные. Однако для правила Сильвермана наблюдается обратная картина. Такие результаты можно объяснить тем, что детерминированная генерация создаёт систематический промежуток в зоне перехода между модами, где оценка

ядерного сглаживания с маленькой шириной окна приводит к выбросу. Случайная генерация вносит дополнительный шум в расположение точек, поэтому такая ситуация встречается реже.

4.2.2.1.2. Анализ очищенных результатов

По результатам оценок (см. рис. 44) можно сделать вывод, что методы кросс-валидации статистически значимо превосходят правило Сильвермана в обоих генерациях по всем метрикам, кроме максимальной ошибки в детерминированном случае, где разница есть, но статистически незначима из-за большой стандартной ошибки $SE_{\overline{MaxErr}}$. При этом оценки 5-fold CV и LOOCV практически не различаются. Кроме того, после учета выбросов оценки при стохастической генерации немного выше, чем при детерминированной, но статистически незначимо, что указывает на относительную робастность методов в среднем случае.




Рис. 44. Сравнение методов по всем оценкам (смесь распределений).

Более подробный анализ показал, что основная причина различий закономерно кроется в адаптивности методов кросс-валидации. Правило Сильвермана всегда выбирало маленькое окно, в то время оптимальная ширина окна в методах кросс-валидации очень сильно варьировалась от датасета к датасету, подстраиваясь под данные (см. рис. 45). Таким образом, можно сделать вывод, что в случае нормальной смеси методы кросс-валидации являются однозначно лучшим методом, по сравнению с правилом Сильвермана.




Рис. 45. Сравнение методов по выбранной ширине окна (смесь распределений).

4.2.2.2. Оценка энтропийным методом

По результатам оценки смесевых датасетов были получены оценки метрик, представленные в Приложении 9.

4.2.2.2.1. Анализ подбора параметров

Распределение подобранных параметров (см. рис. 46) указывает на отсутствие значимых различий в зависимости от вида генерации. В обоих случаях преобладает доля L1 регуляризации, а самые частые степени – это 1 и 2. Таким образом, наблюдается тенденция метода к выбору более простой модели для выбранной структуры данных. Стоит отметить, что в стохастической генерации доля случаев с выбранной высокой степенью (>3) возрастает, что согласуется с адаптацией метода к более случайным данным.




Рис. 46. Характеристики подобранных параметров энтропийного метода для смешанных данных.

4.2.2.2.2. Очистка от выбросов и оценка их влияния

Очистка по методу 1,5 межквартильных размаха привела к удалению 17,3% выборок в среднем, причём ожидаемо в стохастической генерации удалений больше, чем в детерминированной (см. рис. 47). Результаты после очистки представлены в Приложении 10. Обработка очень сильно улучшила средние оценки метрик для обеих генераций, особенно IMSE, где метрика уменьшилась приблизительно в 20 раз, а SEM метрики в 100 раз. Улучшения метрик IMAE и MaxErr тоже были, однако менее значительными (в 1,5-2 раза). Таким образом, можно сделать вывод о существенном влиянии очистки от выбросов на качество результатов. Стоит, однако, отметить, что даже до очистки выбросов метрики были на уровне или лучше результатов ядерной регрессии.




Рис. 47. Влияние очистки от выбросов на смешанных данных для энтропийного метода.

4.2.2.2.3. Анализ очищенных результатов

Анализ результатов оценки регрессии на смесевых данных не выявил значимых различий между метриками для генераций в контексте сравнения энтропийного метода самого с самим. Но если проанализировать результаты до оценки (см. например рис. 47), то можно отметить, что для всех метрик за счёт увеличения случайности на стохастической генерации среднее метрик и их SEM больше.

4.2.2.3. Сравнение методов

Результаты сравнения метрик после очистки от выбросов указывают на явное и сильное превосходство энтропийного метода по всем метрикам во всех конфигурациях (см. рис. 48). Более того, энтропийный метод показывает лучшие метрики в среднем даже если использовать результаты до очистки (см. рис. 49). Все различия после очистки статистически значимы на 0,1% уровне (см. рис. 50). Если сравнивать с результатом до очистки, то статистическая значимость для всех метрик достигается только на детерминированной генерации, в то время как на стохастической шум не позволяет сделать выводы для всех метрик кроме IMAE, где различие значимо на 0,1% уровне при любой генерации (см. рис. 51). Это можно объяснить большей устойчивостью метрики к большим отклонениям. Таким образом, можно сделать вывод, что энтропийный метод в данной части эксперимента не только значительно превосходит ядерные методы по метрикам (в 10-20 раз), но за счёт бутстрапа также является достаточно робастным к малой выборке, чтобы получать результаты лучше ядерных методов до очистки.




Рис. 48. Преимущество энтропийного метода над ядерной регрессией (после IQR).




Рис. 49. Сравнение результатов оценки по метрикам.




Рис. 50. Значимость различий: Энтропия (после IQR) vs Ядерный LOOCV (после IQR).




Рис. 51. Значимость различий: Энтропия (ДО IQR) vs Ядерный LOOCV (ПОСЛЕ IQR).

4.3. Оценка моделей на реальных данных

Как описывалось в главе 2.2, для сравнения подходов на реальных данных использовался датасет по извержениям гейзера Старый Служака. В результате оценки метрик методом 5-fold CV была получена Таблица 1.

Таблица – 1. Результаты оценки качества методов на реальных данных.

Method	$RMSE_{CV}$	MAE_{CV}	$MaxErr_{CV}$
Правило Сильвермана	0.385714	0.305371	1.040429
5-fold CV	0.377969	0.296663	1.087792
LOOCV	0.377177	0.296323	1.088225
Энтропийный подход	0.391797	0.304396	1.079564

Общий анализ результатов указывает на то, что ядерные методы на 3-4% лучше по метрикам на выбранных данных, чем энтропийный подход. Это можно объяснить

несколькими факторами. Во-первых, в предложенном датасете гораздо больше точек даже после разделения для кросс-валидации по сравнению с размерами тестовых датасетов (30 vs 218), поэтому кросс-валидация для подбора ширины окна работает гораздо стабильнее, что улучшает качество оценки ядерных методов. Во-вторых, предложенные данные имеют билинейную структуру, которую ядерная регрессия аппроксимирует естественнее полинома за счёт непараметрического подхода. Однако стоит отметить, что разница метрик достаточно мала и сложно сказать, насколько она значительна. Таким образом, на выбранном датасете ядерные методы показали себя немного лучше, однако сделать вывод о решительном преимуществе не представляется возможным.

Заключение

В ходе выполнения выпускной квалификационной работы был разработан энтропийный метод оценивания регрессионной зависимости, а также был проведён сравнительный анализ предложенного метода с классическими методами ядерной регрессии (правило Сильвермана, 5-fold CV, LOOCV) в условиях малых выборок и ненормально распределённых ошибок. Основным результатом данной работы является экспериментальное подтверждение эффективности метода «мягкой» энтропии по сравнению с выбранными методами ядерной регрессии.

По результатам экспериментов можно сделать ряд ключевых выводов. На синтетических данных предложенный метод показал статистически значимое превосходство над ядерными методами по всем метрикам (IMSE, IMAE, MaxErr) в подавляющей доле случаев, а в остальных случаях энтропийный метод лучше по средним метрикам, но незначимо. На полиномиальных синтетических данных различия становятся значимыми, начиная со второй степени полинома, причем в большинстве случаев статистическая значимость t-теста Уэлча с поправкой Бонферрони составляет 0.1%, что является высоким показателем. На смесевых данных энтропийный метод показал ещё более выраженное преимущество – среднее значение метрики IMSE после очистки оказалось в 10-20 раз ниже в зависимости от уровня шума, а метрики IMAE и MaxErr оказались в 3-5 раз лучше, чем у ядерных методов. Более того, метод показал себя робастным, так как в ряде случаев результаты до очистки от выбросов статистически значимо превосходили результаты ядерной регрессии после очистки. Основной причиной успеха можно выделить высокую адаптивность предложенного подхода за счёт комбинации приблизительного подбора по энтропии и подбора конкретных параметров с помощью .632+ бутстрапа, в то время как ядерные методы давали нестабильные результаты из-за малости выборки.

Оценка регрессии на реальных данных по извержениям гейзера Стары Служака показала, что ядерные методы дают результаты лучше по метрикам RMSE, MAE и MaxErr. Такой результат объясняется двумя факторами. Во-первых, в предложенном датасете объём данных был почти в 10 раз больше, поэтому ядерные методы работали гораздо стабильнее. Во-вторых, непараметрическая природа ядерной регрессии лучше описывала билинейную структуру данных, чем полиномы в предложенном энтропийном подходе. Стоит, однако, отметить, что различие в метриках было незначительным и составило всего 3-4%. Это свидетельствует от конкурентоспособности подхода и отсутствии принципиальных ограничений на его применение в реальных задачах.

Переходя к ограничениям исследуемого метода, в ходе экспериментов было установлено, что предложенный подход склонен к «перестраховке» - чаще выбираются более простые модели, что особенно заметно по результатам на синтетических полиномиальных данных. Эта особенность предотвращает переобучение метода и делает его более стабильным в условиях малых данных и неопределённости, однако ограничивает рост преимущества при усложнении структуры регрессионной зависимости.

Таким образом, результаты работы указывают на то, что предложенный метод «мягкого» энтропийного оценивания целесообразно применять в задачах, в которых объём данных, доступных для исследования, ограничен, а распределение шума не является стандартным или содержит выбросы. В задачах с большими выборками и сложными непараметрическими зависимостями остаются предпочтительными классические непараметрические подходы вроде ядерной регрессии.

Данная работа открывает множество вариантов дальнейшего развития и исследования метода. Одним из самых перспективных является разработка гибридного подхода, объединяющего ядерные методы и энтропийный подход для сочетания устойчивости и гибкости аппроксимации регрессионных зависимостей. Другим направлением является дальнейшая оптимизация вычислительной сложности метода для применения подхода на данных большей размерности.

ПРИЛОЖЕНИЕ 2

Вывод формулы регрессии для двумерной смеси двумерных нормальных распределений

Вывод регрессии в общем виде:

Пусть двумерный вектор (X, Y) имеет распределение смеси:

$$p(x, y) = \pi \cdot \mathcal{N}\left(\begin{bmatrix} x \\ y \end{bmatrix}; \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1\right) + (1 - \pi) \cdot \mathcal{N}\left(\begin{bmatrix} x \\ y \end{bmatrix}; \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2\right), \quad (1)$$

где $\pi \in (0, 1)$ – вес первого компонента, $\boldsymbol{\mu}_k = \begin{bmatrix} \mu_{kx} \\ \mu_{ky} \end{bmatrix}$ – вектор средних для компонента k ,

$\boldsymbol{\Sigma}_k = \begin{bmatrix} \sigma_{kx}^2 & \sigma_{kxy} \\ \sigma_{kxy} & \sigma_{ky}^2 \end{bmatrix}$ – ковариационная матрица для компонента k .

Для смеси условное распределение $p(y|x)$ также является смесью:

$$p(y|x) = \pi(x) \cdot \mathcal{N}(y; \mu_{1|x}, \sigma_{1|x}^2) + (1 - \pi(x)) \cdot \mathcal{N}(y; \mu_{2|x}, \sigma_{2|x}^2), \quad (2)$$

где $\pi(x) = \frac{\pi \cdot p(x|\text{компонента 1})}{p(x)}$ – апостериорная вероятность принадлежности к первому компоненту при условии x согласно теореме Байеса, $p(x) = \pi \cdot p(x|\text{компонента 1}) + (1 - \pi) \cdot p(x|\text{компонента 2})$ – маргинальная плотность x .

Согласно свойствам нормального распределения, условное распределение $Y|X = x$ для каждого компонента k нормально и имеет следующие параметры:

$$\mu_{k|x} = \mu_{ky} + \frac{\sigma_{kxy}}{\sigma_{kx}^2}(x - \mu_{kx}), \quad (3)$$

$$\sigma_{k|x}^2 = \sigma_{ky}^2 - \frac{\sigma_{kxy}^2}{\sigma_{kx}^2}. \quad (4)$$

По свойству условного ожидания для смеси:

$$g(x) = E(Y|X = x) = \pi(x) \cdot \mu_{1|x} + (1 - \pi(x)) \cdot \mu_{2|x}. \quad (5)$$

Определим случайную ошибку ε как:

$$\varepsilon = Y - g(X). \quad (6)$$

Тогда по построению:

$$E(\varepsilon|X = x) = E(Y - g(X)|X = x) = g(x) - g(x) = 0. \quad (7)$$

Таким образом, мы получаем искомое разложение:

$$Y = g(X) + \varepsilon, \text{ где } E(\varepsilon|X) = 0.$$

Вывод формулы истинной регрессии при известных параметрах:

В данной работе взяты следующие параметры компонент для генерации: $\pi = 0.8$, $\mu_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$, $\mu_2 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$, $\Sigma_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, $\Sigma_2 = \begin{bmatrix} 9 & 0 \\ 0 & 9 \end{bmatrix}$.

Поскольку ковариации в обоих компонентах равны нулю, то в силу нормальности распределений X и Y независимы внутри каждого компонента. Тогда:

- Для компонента 1:

$$Y | X = x, \text{ компонент 1} \sim \mathcal{N}(1,1) \Rightarrow E(Y | X = x, \text{ компонент 1}) = 1.$$

- Для компонента 2:

$$Y | X = x, \text{ компонент 2} \sim \mathcal{N}(3,9) \Rightarrow E(Y | X = x, \text{ компонент 2}) = 3.$$

По формуле Байеса вычислим апостериорные вероятности принадлежности к компонентам при условии $X = x$:

$$\begin{aligned} \pi(x) &= P(\text{компонент 1} | X = x) \\ &= \frac{\pi \cdot p(x | \text{компонент 1})}{\pi \cdot p(x | \text{компонент 1}) + (1 - \pi) \cdot p(x | \text{компонент 2})}, \end{aligned}$$

где $p(x | \text{компонент } k)$ – маргинальная плотность X в компоненте k .

Подставляем указанные выше параметры смеси:

$$\pi(x) = \frac{0.8 \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-1)^2}{2}\right)}{0.8 \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-1)^2}{2}\right) + 0.2 \cdot \frac{1}{3\sqrt{2\pi}} \exp\left(-\frac{(x-3)^2}{18}\right)} = \frac{0.8 \cdot A}{0.8 \cdot A + \frac{1}{15} \cdot B},$$

где $A = \exp\left(-\frac{(x-1)^2}{2}\right)$, $B = \exp\left(-\frac{(x-3)^2}{18}\right)$.

Условное математическое ожидание:

$$g(x) = E(Y|X = x) = \pi(x) \cdot 1 + (1 - \pi(x)) \cdot 3 = 3 - 2\pi(x).$$

Подставляем $\pi(x)$:

$$g(x) = 3 - 2 \cdot \frac{0.8 \cdot A}{0.8 \cdot A + \frac{1}{15} \cdot B} = 3 - \frac{24 \cdot A}{24 \cdot A + B}.$$

Возвращаем А и В:

$$g(x) = 3 - \frac{24 \cdot \exp\left(-\frac{(x-1)^2}{2}\right)}{24 \cdot \exp\left(-\frac{(x-1)^2}{2}\right) + \exp\left(-\frac{(x-3)^2}{18}\right)}. \quad (8)$$

Эта формула и является истинным уравнением регрессии в данном случае.

ПРИЛОЖЕНИЕ 3

Результаты оценки полиномиальных данных методами ядерной регрессии

Таблица 1. Результаты оценки ядерной регрессии на полиномиальных данных (1 степень).

Источник: Работа автора.

Шум	Метод	$\overline{IMSE}$	$SE_{\overline{IMSE}}$	$\overline{IMAE}$	$SE_{\overline{IMAE}}$	$\overline{MaxErr}$	$SE_{\overline{MaxErr}}$
low	silverman	0,160	0,016	0,279	0,007	0,538	0,035
low	5-fold cv	0,146	0,013	0,264	0,009	0,521	0,024
low	loocv	0,187	0,054	0,265	0,010	0,597	0,086
moderate	silverman	0,176	0,029	0,277	0,009	0,532	0,032
moderate	5-fold cv	0,166	0,034	0,258	0,012	0,516	0,031
moderate	loocv	0,168	0,035	0,264	0,012	0,517	0,029
high	silverman	0,178	0,019	0,282	0,008	0,534	0,036
high	5-fold cv	0,157	0,015	0,270	0,009	0,533	0,024
high	loocv	0,151	0,014	0,268	0,009	0,514	0,021

Таблица 2. Результаты оценки ядерной регрессии на полиномиальных данных (2 степень).

Источник: Работа автора.

Шум	Метод	$\overline{IMSE}$	$SE_{\overline{IMSE}}$	$\overline{IMAE}$	$SE_{\overline{IMAE}}$	$\overline{MaxErr}$	$SE_{\overline{MaxErr}}$
low	silverman	0,421	0,029	0,478	0,017	0,788	0,031
low	5-fold cv	0,868	0,477	0,406	0,015	0,696	0,029
low	loocv	0,781	0,469	0,398	0,014	0,693	0,028
moderate	silverman	0,266	0,020	0,383	0,013	0,647	0,024
moderate	5-fold cv	0,378	0,079	0,375	0,012	0,669	0,029
moderate	loocv	0,394	0,085	0,370	0,012	0,673	0,040

high	silverman	0,250	0,026	0,356	0,012	0,617	0,030
high	5-fold cv	0,268	0,033	0,351	0,011	0,618	0,034
high	loocv	0,295	0,044	0,354	0,012	0,667	0,047

Таблица 3. Результаты оценки ядерной регрессии на полиномиальных данных (3 степень).

Источник: Работа автора.

Шум	Метод	$\overline{IMSE}$	$SE_{\overline{IMSE}}$	$\overline{IMAE}$	$SE_{\overline{IMAE}}$	$\overline{MaxErr}$	$SE_{\overline{MaxErr}}$
low	silverman	0,442	0,043	0,469	0,017	0,814	0,035
low	5-fold cv	0,428	0,098	0,406	0,011	0,729	0,031
low	loocv	0,335	0,032	0,396	0,010	0,716	0,029
moderate	silverman	0,324	0,038	0,396	0,013	0,673	0,028
moderate	5-fold cv	0,405	0,070	0,394	0,013	0,723	0,041
moderate	loocv	0,417	0,059	0,399	0,013	0,756	0,042
high	silverman	0,194	0,019	0,319	0,010	0,577	0,031
high	5-fold cv	0,224	0,022	0,331	0,009	0,560	0,022
high	loocv	0,358	0,115	0,343	0,012	0,609	0,033

Таблица 4. Результаты оценки ядерной регрессии на полиномиальных данных (4 степень).

Источник: Работа автора.

Шум	Метод	$\overline{IMSE}$	$SE_{\overline{IMSE}}$	$\overline{IMAE}$	$SE_{\overline{IMAE}}$	$\overline{MaxErr}$	$SE_{\overline{MaxErr}}$
low	silverman	0,653	0,078	0,541	0,021	0,946	0,042
low	5-fold cv	0,410	0,052	0,421	0,012	0,744	0,032
low	loocv	0,396	0,050	0,416	0,011	0,765	0,039
moderate	silverman	0,390	0,035	0,429	0,016	0,747	0,031
moderate	5-fold cv	0,370	0,041	0,397	0,012	0,780	0,055

moderate	loocv	0,391	0,057	0,394	0,012	0,737	0,038
high	silverman	0,295	0,041	0,369	0,013	0,648	0,035
high	5-fold cv	0,376	0,088	0,378	0,012	0,686	0,028
high	loocv	0,384	0,092	0,377	0,012	0,686	0,031

Таблица 5. Результаты оценки ядерной регрессии на полиномиальных данных (5 степень).

Источник: Работа автора.

Шум	Метод	$\overline{IMSE}$	$SE_{\overline{IMSE}}$	$\overline{IMAE}$	$SE_{\overline{IMAE}}$	$\overline{MaxErr}$	$SE_{\overline{MaxErr}}$
low	silverman	0,786	0,070	0,606	0,021	1,120	0,043
low	5-fold cv	0,826	0,368	0,454	0,017	0,904	0,061
low	loocv	1,090	0,472	0,469	0,019	0,903	0,047
moderate	silverman	0,413	0,031	0,454	0,014	0,824	0,032
moderate	5-fold cv	0,411	0,053	0,410	0,011	0,819	0,055
moderate	loocv	0,541	0,164	0,410	0,015	0,845	0,060
high	silverman	0,303	0,027	0,380	0,011	0,653	0,030
high	5-fold cv	0,401	0,073	0,388	0,011	0,645	0,022
high	loocv	1,232	0,878	0,400	0,018	0,671	0,028

Таблица 6. Результаты оценки ядерной регрессии на полиномиальных данных (6 степень).

Источник: Работа автора.

Шум	Метод	$\overline{IMSE}$	$SE_{\overline{IMSE}}$	$\overline{IMAE}$	$SE_{\overline{IMAE}}$	$\overline{MaxErr}$	$SE_{\overline{MaxErr}}$
low	silverman	0,972	0,073	0,660	0,022	1,281	0,051
low	5-fold cv	0,606	0,086	0,469	0,012	0,913	0,043
low	loocv	0,580	0,086	0,461	0,012	0,850	0,033
moderate	silverman	0,591	0,079	0,499	0,018	0,940	0,043

moderate	5-fold cv	0,465	0,122	0,414	0,013	0,804	0,072
moderate	loocv	0,460	0,120	0,410	0,013	0,827	0,076
high	silverman	0,320	0,035	0,396	0,012	0,683	0,026
high	5-fold cv	0,286	0,020	0,379	0,010	0,722	0,035
high	loocv	0,337	0,041	0,383	0,011	0,793	0,055