

ОЦЕНИВАНИЕ РЕГРЕССИИ: СРАВНЕНИЕ НЕПАРАМЕТРИЧЕСКОГО И ИНФОРМАЦИОННОГО ПОДХОДОВ

Автор: Анфимов А. Д.

Научный руководитель: Булычёв А. В.

Направление: «Системный анализ и управление в больших системах»

Дата: 23.05.2026

Проблема и актуальность

Проблема построения регрессионных моделей:

- Классический МНК требует выполнения стандартных условий (нормальность ошибок, достаточный для точности объём выборки)
- Непараметрические методы (ядерная регрессия) не эффективны при малом количестве точек

Научная новизна:

- Применение модифицированного энтропийного метода с «мягкой» рандомизацией к оценке регрессии
- Сравнение с ядерной регрессией на синтетических данных с различными распределениями ошибок

Цель и задачи исследования

Цель:

Построение робастных оценок регрессии на малых выборках без предположений о виде распределения ошибок

Задачи:

1. Реализовать энтропийный метод оценивания
2. Сравнить с ядерной регрессией
3. Оценить чувствительность решения к различным уровням шума

Непараметрический подход

Основы классического ядерного сглаживания:

В каждой точке вычисляется сглаженная оценка функции плотности с помощью весов, определяемых ядром и полосой пропускания (окном) по формуле Розенבלата-Парзена:

$$\widehat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

где x_i — элементы выборки, $K(x)$ — ядерная функция, h — полоса пропускания (окно сглаживания).

В задаче регрессии оценка плотности используется для вычисления ядерных весов:

$$W_{ni}(x) = \frac{K_{h_n}(x - x_i)}{\widehat{f}_{h_n}(x)}$$

где $K_h(x) = \frac{1}{h} K\left(\frac{x}{h}\right)$, а ширина окна $h = h_n$ зависит от объёма выборки.

Данная весовая схема применяется для оценки условного математического ожидания $E(y|x)$, по формуле Надарая-Ватсона:

$$\widehat{g}_h(x) = \frac{\frac{1}{n} \sum_{i=1}^n y_i K_{h_n}(x - x_i)}{\frac{1}{n} \sum_{i=1}^n K_{h_n}(x - x_i)}$$

Непараметрический подход

Выбор ширины окна:

В работе используются три подхода:

1. **Правило Сильвермана** — эмпирическое правило, не зависит от u . Используется как baseline;
2. **5-fold кросс-валидация** — делит выборку на 5 частей, минимизирует усреднённую по фолдам MSE;
3. **LOOCV (leave-one-out)** — последовательно оставляет по одной точке для тестирования, обучается на остальных и усредняет ошибку по всем итерациям.

Ключевое ограничение: нестабильность на малых выборках.

Энтропийный подход

Основы классического энтропийного метода:

Пусть оцениваемая зависимость $g(x)$ представляет собой модель с параметрами $a \in R^r$, где r — количество параметров, т. е.

$$y = g(x, a) + \varepsilon, a \in R^r$$

Параметры a и ошибки ε предполагаются непрерывными случайными величинами, которые определены на некоторых интервалах $a \in A = [a^-, a^+]$ и $\varepsilon \in U = [\varepsilon^-, \varepsilon^+]$. Целью является восстановление по данным оптимальных функций плотности распределения (ФПР) случайных величин $Q(\varepsilon)$ и $P(a)$ путем максимизации функционала информационной энтропии:

$$H(P(a), Q(\varepsilon)) = - \int_A P(a) \ln P(a) da - \int_U Q(\varepsilon) \ln Q(\varepsilon) d\varepsilon \rightarrow \max_{P, Q}$$

Энтропийный подход

Основы «мягкого» энтропийного метода:

Используется гильбертова норма разности невязки:

$$N_a(a) = \|g(x, a) - y\|_H,$$

$$N_\varepsilon(\varepsilon) = \|\varepsilon\|_H.$$

Задача сводится к максимизации функционала $J(P(a), Q(\varepsilon))$, объединяющего энтропию, «эмпирический риск» и среднюю норму ошибок, при условиях нормировки $P(a)$ и $Q(\varepsilon)$:

$$J(P(a), Q(\varepsilon)) = H(P(a), Q(\varepsilon)) - E(N_a(a)) - E(N_\varepsilon(\varepsilon)).$$

Для учета ограничений вводится функционал Лагранжа, а условия оптимальности через производные Гато.

Решение задачи в общем виде имеет вид:

$$P^*(a) = \frac{\exp(-N_a(a))}{\int_A \exp(-N_a(a)) da}, Q^*(\varepsilon) = \frac{\exp(-N_\varepsilon(\varepsilon))}{\int_U \exp(-N_\varepsilon(\varepsilon)) d\varepsilon}.$$

В качестве нормы в данном исследовании берется комбинация L_1 и L_2 норм:

$$N_a(a) = c_1 \|\hat{y} - y\|_1 + c_2 \|\hat{y} - y\|_2$$

Дизайн эксперимента

Параметр	Значение
Объём выборки	30 точек
Модели регрессии	Полиномы 1-6 степени; Двумерная смесь нормальных распределений ($E(y x)$)
Количество датасетов на комбинацию	300
Методы ядерной регрессии	Правило Сильвермана, 5-fold CV, LOOCV
Метод подбора степени полинома и параметров c_1 и c_2	632+ бутстрап
Метрики	Интегральная среднеквадратичная ошибка (IMSE) Интегральная средняя абсолютная ошибка (IMAE) Максимальная ошибка (MaxErr)
Генерация ошибок для полиномов	
Распределения ошибок	Лапласа, Гумбеля, Тьюки и др. (30 типов)
Уровни шума (коэффициент детерминации R)	0.95 (низкий), 0.9 (средний), 0.8 (высокий)

Дизайн эксперимента

Для проверки на реальных данных использовался датасет по извержениям гейзера Старый служака.




Рис. 1. Зависимость между продолжительностью извержения и временем ожидания, Гейзер "Старый Служака" (Озеро Йеллоустон).

Методология сравнения методов

Используемые статистические подходы:

- Для сравнения ядерных методов друг с другом использовался **тест Фридмана с поправкой Бонферрони**;
- Для сравнения энтропийного подхода с непараметрическими использовался **тест Уилкоксона с поправкой Холма**;
- Для проверки устойчивости результаты дополнительно сравнивались на наборе датасетов, очищенном от выбросов по методу **1,5 IQR**.

Результаты: полиномиальные данные

Основные наблюдения по сравнению ядерных методов:

- Преимущество методов кросс-валидации перед эмпирическим наблюдается только для низкого шума и высоких степеней.




Рис. 2. Сравнение методов ядерного сглаживания по IMSE на полиномиальных данных после очистки от выбросов

Результаты: полиномиальные данные

Основные наблюдения:

- Энтропийный метод демонстрирует эффективность во всех конфигурациях по всем метрикам;
- В 96% конфигураций различия статистически значимы на уровне 0,1%;
- Размер эффекта (rank-biserial) в большинстве случаев умеренный $r \in [0.3, 0.5]$;
- Наибольшее улучшение по IMSE достигнуто для полинома 2-й степени (-47,8% к ядерной регрессии).




Рис. 3. Сравнение лучших оценок ядерного и энтропийного подходов по IMSE на полиномиальных данных

Результаты: смесевые данные

Основные наблюдения по сравнению ядерных методов:

- Преимущество методов кросс-валидации перед эмпирическим правилом наблюдается по всем метрикам, кроме максимальной ошибки.




Рис. 4. Сравнение методов ядерного сглаживания по IMSE на смесевых данных после очистки от выбросов

Результаты: смесевые данные

Основные наблюдения:

- Энтропийный метод демонстрирует сильное преимущество во всех конфигурациях по всем метрикам;
- Все различия значимы на уровне 0,1% как до, так и после очистки от выбросов;
- Размер эффекта (rank-biserial) большой во всех случаях $r > 0,5$. После очистки достигает 0,86-0,87;
- Среднее улучшение по IMSE 95,9%.




Рис. 5. Сравнение лучших оценок ядерного и энтропийного подходов по IMSE на смесевых данных

Результаты: реальные данные

Таблица – 1. Результаты оценки качества методов на реальных данных.

Метод	$RMSE_{cv}$	MAE_{cv}	$MaxErr_{cv}$
Правило Сильвермана	0.386	0.305	1.040
5-fold CV	0.378	0.297	1.088
LOOCV	0.378	0.296	1.088
Энтропийный подход	0.392	0.304	1.080

Основные наблюдения:

- ядерные методы показали чуть лучшие значения метрик (разница 3–4%);

Ограничения энтропийного метода

Основное ограничение: склонность к консервативному выбору моделей (так называемая «перестраховка»)




Рис. 6. Систематическое смещение подбора степени полинома в энтропийном подходе.

Заключение

Выводы:

- Энтропийный метод с «мягкой» рандомизацией **эффективен на малых выборках и робастен к распределению ошибок;**
- На синтетических данных метод статистически значимо превосходит ядерную регрессию **на уровне значимости 0, 1%** в большинстве конфигураций;
- На реальных данных метод конкурентоспособен, уступая на 3–4% ядерным методам по выбранным метрикам;
- Наибольший выигрыш для **низкого уровня шума ($R^2 = 0.95$) и полиномов низкой степени (2-3).**

Перспективы развития

Возможные направления:

- Разработка **гибридного подхода**, объединяющего ядерный и энтропийный методы для сохранения устойчивости и гибкости аппроксимации;
- Развитие вычислительных методов для работы с данными большой размерности, связанных с семплированием по методу Монте-Карло.

СПАСИБО ЗА ВНИМАНИЕ