

ЭНТРОПИЙНЫЙ ПОДХОД ДЛЯ РОБАСТНОГО ОЦЕНИВАНИЯ РЕГРЕССИОННЫХ ЗАВИСИМОСТЕЙ

Автор: Анфимов А. Д.

Организация: Московский физико-технический институт (национальный исследовательский университет)

Дата: 04.04.2026

Проблема и актуальность

Проблема построения регрессионных моделей:

- Классический МНК требует выполнения стандартных условий (нормальность ошибок, достаточный для точности объём выборки)
- Непараметрические методы (ядерная регрессия) не эффективны при малом количестве точек

Научная новизна:

- Применение модифицированного энтропийного метода с «мягкой» рандомизацией [1] к оценке регрессии
- Сравнение с ядерной регрессией на синтетических данных с различными распределениями ошибок

Цель и задачи исследования

Цель:

Построение робастных оценок регрессии на малых выборках без предположений о виде распределения ошибок

Задачи:

1. Реализовать энтропийный метод оценивания
2. Сравнить с ядерной регрессией
3. Оценить чувствительность решения к различным уровням шума

Энтропийный подход

Основы классического энтропийного метода [2]:

Пусть оцениваемая зависимость $g(x)$ представляет собой модель с параметрами $a \in R^r$, где r — количество параметров, т. е.

$$y = g(x, a) + \varepsilon, a \in R^r$$

Параметры a и ошибки ε предполагаются непрерывными случайными величинами, которые определены на некоторых интервалах $a \in A = [a^-, a^+]$ и $\varepsilon \in U = [\varepsilon^-, \varepsilon^+]$. Целью является восстановление по данным оптимальных функций плотности распределения (ФПР) случайных величин $Q(\varepsilon)$ и $P(a)$ путем максимизации функционала информационной энтропии:

$$H(P(a), Q(\varepsilon)) = - \int_A P(a) \ln P(a) da - \int_U Q(\varepsilon) \ln Q(\varepsilon) d\varepsilon \rightarrow \max_{P, Q}$$

Энтропийный подход

Основы «мягкого» энтропийного метода:

Используется гильбертова норма разности невязки [3]:

$$N_a(a) = \|g(x, a) - y\|_H,$$

$$N_\varepsilon(\varepsilon) = \|\varepsilon\|_H.$$

Задача сводится к максимизации функционала $J(P(a), Q(\varepsilon))$, объединяющего энтропию, «эмпирический риск» [4] и среднюю норму ошибок, при условиях нормировки $P(a)$ и $Q(\varepsilon)$:

$$J(P(a), Q(\varepsilon)) = H(P(a), Q(\varepsilon)) - E(N_a(a)) - E(N_\varepsilon(\varepsilon)).$$

Для учета ограничений вводится функционал Лагранжа, а условия оптимальности через производные Гато.

Решение задачи в общем виде имеет вид:

$$P^*(a) = \frac{\exp(-N_a(a))}{\int_A \exp(-N_a(a)) da}, Q^*(\varepsilon) = \frac{\exp(-N_\varepsilon(\varepsilon))}{\int_U \exp(-N_\varepsilon(\varepsilon)) d\varepsilon}.$$

В качестве нормы в данном исследовании берется комбинация L_1 и L_2 норм:

$$N_a(a) = c_1 \|\hat{y} - y\|_1 + c_2 \|\hat{y} - y\|_2$$

Дизайн эксперимента

Параметр	Значение
Объём выборки	30 точек
Степени полинома	1-6
Распределения ошибок	Лапласа, Гумбеля, Тьюки и др. (30 типов)
Уровни шума (коэффициент детерминации R)	0.95 (низкий), 0.9 (средний), 0.8 (высокий)
Количество датасетов на комбинацию	30
Методы ядерной регрессии	Правило Сильвермана, 5-fold CV, LOOCV
Метод подбора степени полинома и параметров c_1 и c_2	632+ бутстрап [5]
Метрики	Интегральная среднеквадратичная ошибка (IMSE) Интегральная средняя абсолютная ошибка (IMAE) Максимальная ошибка (MaxErr)

Результаты

Основные наблюдения:

- Энтропийный метод демонстрирует эффективность при всех уровнях шума
- Наибольшее улучшение достигнуто для полинома 2-й степени (-63% к ядерной регрессии)




Рис.1. Сравнение лучших оценок ядерного и энтропийного метода по IMSE

Заключение

Выводы:

- На малых выборках ($n=30$) кросс-валидация **нестабильна**;
- Энтропийный метод статистически эффективнее в **большинстве конфигураций**
- Метод **робастен** к распределению ошибок (не требует нормальности)
- Работает устойчиво при **малом объёме выборки** ($n=30$)
- Наибольший выигрыш для **низкого уровня шума** ($R^2 = 0.95$) и полиномов низкой степени (**2-3**)

СПАСИБО ЗА ВНИМАНИЕ

Список литературы

1. *Дубнов Ю. А., Булычев А. В.* Приближенное оценивание с помощью ускоренного метода наибольшей энтропии.

Часть 1. Постановка задачи и реализация для задачи регрессии // Информационные технологии и вычислительные системы. 2022. № 4. С. 69–80.

2. *Golan A., Judge G. G., Miller D.* Maximum Entropy Econometrics: Robust Estimation with Limited Data. —

Chichester: John Wiley and Sons Ltd., 1996.

3. *Воеводин В. В., Кузнецов Ю. А.* Матрицы и вычисления. — М.: Наука, 1984.

4. *Цыпкин Я. З.* Основы теории обучающихся систем. — М.: Наука, 1970.

5. *Efron B., Tibshirani R.* Improvements on cross-validation: the 632+ bootstrap method // J. Am. Stat. Assoc. 1997. V.

92(438). P. 548–560.